Monthly Notices of the ROYAL ASTRONOMICAL SOCIETY
MNRAS **475,** 2978-2993 (2018) doi:10.1093/mnras/stx3298
Publikasi Advance Access 2017 26 Desember

Aplikasi pembelajaran mendalam dalam analisis spektrum bintang

S. Fabbro,[1'] K. A. Venn,[(2)(')] T. O'Briain,[1,2] S. Bialek,[(1)(,)2] C. L. Kielty,[2] F. Jahandar[(2)]) dan S. Monty[2]

[1] *Dewan Riset Nasional Kanada, Program Astronomi & Astrofisika Herzberg, 5071 West Saanich Road, Victoria, BC, V9E 2E7, Kanada*
[2] *Departemen Fisika dan Astronomi, Universitas Victoria, Victoria, BC V8W 3P2, Kanada*

Diterima 18 Desember 2017. Diterima 18 Desember 2017; dalam bentuk asli 6 Agustus 2017

ABSTRAK

Survei spektroskopi membutuhkan metode analisis yang cepat dan efisien untuk memaksimalkan dampak ilmiahnya. Di sini, kami menerapkan arsitektur jaringan syaraf tiruan untuk menganalisis SDSS-III APOGEE DR13 dan spektrum bintang sintetis. Ketika model jaringan saraf konvolusi kami (StarNet) dilatih pada spektrum APOGEE, kami menunjukkan bahwa parameter bintang (temperatur, gravitasi, dan metalitas) ditentukan dengan ketepatan dan akurasi yang sama dengan pipa APOGEE. StarNet juga dapat memprediksi parameter bintang ketika dilatih dengan data sintetis, dengan presisi dan akurasi yang sangat baik untuk data APOGEE dan data sintetis, pada berbagai rasio sinyal terhadap derau. Selain itu, ketidakpastian statistik dalam penentuan parameter bintang sebanding dengan perbedaan antara hasil pipeline APOGEE dan yang ditentukan secara independen dari spektrum optik. Kami membandingkan StarNet dengan metode berbasis data lainnya; sebagai contoh, StarNet dan Cannon 2 menunjukkan perilaku yang sama ketika dilatih dengan set data yang sama; namun, StarNet berkinerja buruk pada set data kecil seperti yang digunakan oleh Cannon asli. Pengaruh fitur spektral pada parameter bintang diperiksa melalui turunan parsial dari hasil model StarNet sehubungan dengan spektrum input. Meskipun StarNet dikembangkan dengan menggunakan spektrum yang diamati APOGEE dan data sintetik ASSET yang sesuai, kami menyarankan agar teknik ini dapat diterapkan pada rentang panjang gelombang lain dan survei spektral lainnya.

Kata kunci: metode: numerik - teknik: spektroskopi - survei - bintang: parameter fundamental - inframerah: bintang.

1 PENDAHULUAN

Survei spektroskopi menyediakan basis data yang homogen dari spektrum bintang yang ideal untuk aplikasi pembelajaran mesin. Berbagai teknik telah dipelajari dalam dua dekade terakhir. Mulai dari pipeline parameter bintang SDSS SEGUE yang menggunakan arsitektur pohon keputusan antara pencocokan spektral dengan kisi sintetis dan pengukuran indeks garis (misalnya Allende-Prieto dkk. 2008; Lee dkk. 2008; Yanny dkk. 2009; Lee dkk. 2011) hingga algoritme terperinci yang digunakan untuk analisis data spektroskopi *Gaia* (misalnya Smiljanic dkk. 2014; Recio-Blanco 2016, 2017; Pancino dkk. 2017).

Penggunaan jaringan syaraf tiruan (JST) dalam aplikasi astrofisika memiliki sejarah lebih dari 20 tahun, dengan penelitian perintis dalam klasifikasi bintang oleh para penulis seperti Von Hippel dkk. (1994) dan Singh, Gulati & Gupta (1998). Dalam Bailer-Jones dkk. (1997) dan Bailer-Jones (2000), NN diaplikasikan pada spektrum bintang sintetis untuk memprediksi temperatur efektif $T_{\rm eff}$, gravitasi permukaan log g, dan metalitas [Fe/H].

Baru-baru ini, peningkatan dramatis telah terjadi dalam kemampuan dan kinerja algoritme yang diimplementasikan dalam perangkat lunak pembelajaran mesin. Hal ini, dikombinasikan dengan peningkatan daya komputasi dan ketersediaan kumpulan data yang besar, telah mengarah pada implementasi arsitektur NN yang lebih kompleks. Hal ini telah terbukti sangat penting dalam tugas-tugas pengenalan gambar yang sulit dan pemrosesan bahasa alami. Upaya awal NN untuk analisis spektrum bintang (misalnya Bailer-Jones 2000; Manteiga et al. 2010) akan melatih NN pada spektrum sintetis dan menguji model pada spektrum sintetis. Metode pembelajaran mesin juga digunakan dalam salah satu pipeline SEGUE (Lee dkk. 2008), di mana dua NN dilatih: satu pada spektrum sintetis dan yang lainnya pada parameter SEGUE sebelumnya.

Dalam makalah ini, kami mengkaji beberapa kasus pelatihan spektrum sintetik dan prediksi parameter bintang pada spektrum sintetik dan spektrum teramati, atau pelatihan dan prediksi pada spektrum teramati dalam pendekatan berbasis data. Metode yang kami gunakan adalah pendekatan pembelajaran terawasi, di mana subset representatif dari spektrum bintang (baik sintetik maupun observasi) dengan parameter bintang yang diketahui dipilih. Subset ini dapat dibagi lagi menjadi referensi, di mana JST mempelajari fungsi pemetaan dari spektrum ke parameter bintang, dan himpunan uji, yang digunakan untuk memastikan keakuratan prediksi. Setelah model jaringan dilatih (yaitu dengan

^ E-mail: sebastien.fabbro@nrc-cnrc.gc.ca (SF);kvenn@uvic.ca (KAV)

©2017 Penulis
Diterbitkan oleh Oxford University Press atas nama Royal Astronomical Society

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

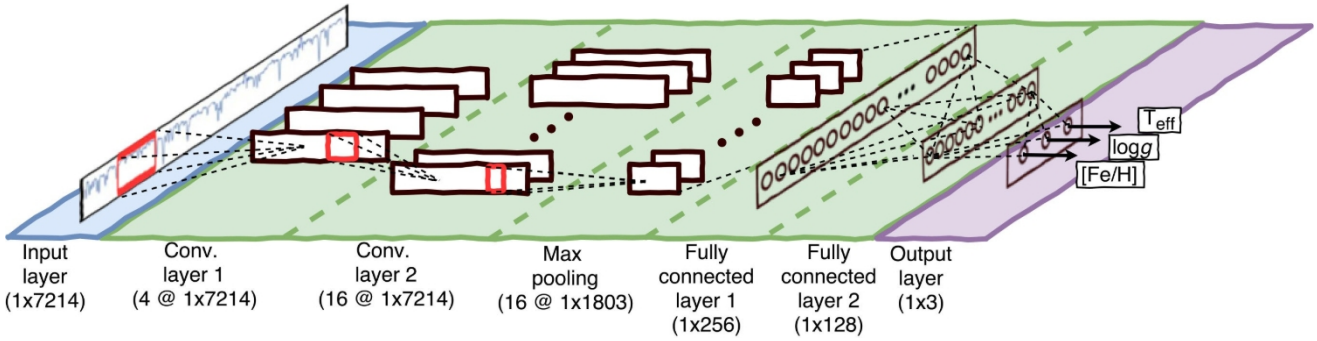

Gambar 1. Model StarNet CNN saat ini terdiri dari tujuh lapisan. Lapisan pertama adalah data input; diikuti oleh dua lapisan konvolusi dengan 4 dan 16 filter (secara berurutan), kemudian lapisan max pooling dengan panjang jendela empat unit, diikuti oleh tiga lapisan yang terhubung penuh dengan 256, 128, dan 3 node (sekali lagi, secara berurutan). Lapisan terakhir adalah lapisan output.

parameter jaringan), parameter bintang dapat diprediksi untuk sampel lainnya. Parameter bintang yang kami pertimbangkan untuk analisis spektral ini adalah temperatur efektif ($T_{\rm eff}$), gravitasi permukaan (log *g*), dan metalitas ([Fe/H]).

Dalam makalah ini, kami menyajikan StarNet: sebuah model jaringan syaraf tiruan (CNN) yang diterapkan pada analisis spektrum bintang. Kami memperkenalkan metode pembelajaran mesin kami di Bagian 2 dan mengevaluasi model kami untuk satu set data sintetis di Bagian 3. Sebagai latihan keefektifannya, kami menerapkan StarNet pada survei APOGEE di Bagian 4 (DR13 dan rilis data sebelumnya jika sesuai) dan membandingkan parameter bintang dengan parameter dari pipa APOGEE. Pada Bagian 5, kami membahas keberhasilan hasil StarNet pada analisis bintang lainnya dan mengonfirmasi bahwa NN dapat secara signifikan meningkatkan ketahanan, efisiensi, dan dampak ilmiah survei spektroskopi.

2 METODOLOGI PEMBELAJARAN MESIN

Pembelajaran terawasi telah terbukti dapat diadaptasi dengan baik untuk masalah regresi variabel berkelanjutan. Diberikan set pelatihan di mana, untuk setiap spektrum input, ada parameter bintang yang diketahui, model pembelajaran yang diawasi kemudian mampu memperkirakan fungsi yang mengubah spektrum input menjadi nilai output. Fungsi yang dipelajari kemudian idealnya dapat digunakan untuk memprediksi nilai keluaran dari kumpulan data yang berbeda. Bentuk khusus dari fungsi ini dan bagaimana fungsi ini dipelajari tergantung pada arsitektur NN. Rangkuman di bawah ini adalah CNN yang telah kami terapkan untuk analisis spektrum bintang; kami memberikan rincian lebih lanjut tentang deep NN dan operasi matematika dari arsitektur yang kami pilih di Lampiran A.

2.1 StarNet CNN

NN dapat disusun dalam lapisan-lapisan neuron buatan: *lapisan input* (yaitu data input), sejumlah *lapisan tersembunyi*, dan *lapisan output.* Tergantung pada arsitektur NN, mungkin ada beberapa lapisan tersembunyi, masing-masing terdiri dari beberapa neuron yang membobotkan dan mengimbangi output dari lapisan sebelumnya untuk menghitung nilai input untuk lapisan berikutnya. Semakin banyak lapisan tersembunyi yang digunakan dalam NN, semakin *dalam* modelnya. Kombinasi lapisan-lapisan ini bertindak sebagai satu fungsi, dan dalam kasus StarNet, fungsi ini memprediksi tiga parameter bintang.

Terinspirasi dari penelitian terbaru tentang deep NN pada spektrum bintang (Li, Pan & Duan 2017; Wang, Guo & Luo 2017), kami memfokuskan analisis kami pada arsitektur deep. CNN yang dipilih untuk StarNet ditunjukkan secara skematis pada Gambar 1. Arsitektur ini terdiri dari kombinasi lapisan yang terhubung sepenuhnya dan satu dimensi (1D) lapisan konvolusi. Lapisan yang terhubung penuh adalah lapisan NN klasik yang menghitung beberapa kombinasi linier dari semua nilai input untuk menghasilkan vektor output. Dalam kasus lapisan convolutional, serangkaian filter diterapkan, mengekstraksi informasi lokal dari lapisan sebelumnya. Selama fase pelatihan, jaringan mempelajari filter yang diaktifkan paling kuat ketika mendeteksi fitur tertentu, sehingga menghasilkan kumpulan *peta fitur*. Dengan menggunakan dua lapisan konvolusi yang berurutan, lapisan kedua akan melintasi peta fitur dari lapisan sebelumnya, yang memungkinkan model untuk mempelajari fitur-fitur dengan tingkat yang lebih tinggi.

Kombinasi lapisan konvolusi dan lapisan yang terhubung penuh dalam implementasi StarNet kami berarti bahwa parameter keluaran tidak hanya dipengaruhi oleh fitur individu dalam spektrum masukan, tetapi juga, kombinasi fitur yang ditemukan di berbagai area spektrum yang berbeda juga digunakan. Teknik ini memperkuat kemampuan StarNet untuk menggeneralisasi prediksinya pada spektrum dengan berbagai rasio sinyal terhadap derau (S/N) pada ruang parameter bintang yang lebih besar. Rincian lebih lanjut tentang model StarNet sendiri dibahas di Bagian 4.3.

2.2 Pelatihan dan pengujian model

Sebelum melatih model, set referensi dibagi menjadi set pelatihan dan set validasi silang. Pelatihan dilakukan melalui serangkaian iterasi perambatan maju dan mundur, menggunakan kumpulan set pelatihan. Perambatan maju adalah fungsi model itu sendiri: pada setiap lapisan, bobot diterapkan pada semua nilai input, dan pada lapisan output, prediksi dihitung. Prediksi ini kemudian dibandingkan dengan nilai target melalui *fungsi* kerugian. Dalam model StarNet kami, fungsi kerugian mean-squared-error (MSE) menghitung kerugian antara prediksi dan nilai target dan total kerugian untuk semua contoh pelatihan diminimalkan.

Pada awalnya, bobot model ditetapkan secara acak dan prediksinya akan sangat buruk. Untuk meningkatkan prediksi ini, bobot model diperbarui setelah setiap perambatan maju. Oleh karena itu, bobot disesuaikan beberapa kali per *iterasi.* Minimum biasanya dicapai setelah 20-25 iterasi (meskipun ini dapat sangat bervariasi tergantung pada kompleksitas model yang digunakan). Pelatihan model StarNet kami mencapai kon
vergence dalam jumlah waktu yang bergantung pada ukuran set pelatihan dan arsitektur model; untuk~ 41.000 spektrum (mendekati 300 juta nilai intensitas) dan 7,5 juta parameter NN, proses
pelatihan terkonvergensi dalam 30 menit, menggunakan mesin virtual 16 core.

Ketika tahap pelatihan mencapai konvergensi, nilai bobot dibekukan. Model yang diestimasi dievaluasi pada satu set uji spektrum dengan berbagai macam S/N. Semua pengujian StarNet dikuantifikasi dengan

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

Tabel 1. Distribusi parameter bintang pada kisi-kisi spektrum sintetik ASSET.

Kelas		Teff	log *g*	(M / H)	(C/M)	(N/M)	(α/M)
	Min	3500	0	-2.5	−1	−1	−1
GK	Max	6000	5	0.5	1	1	1
	Langkah	250	0.5	0.5	0.25	0.5	0.25
	Min	5500	1	-2.5	−1	−1	−1
F	Max	8000	5	0.5	1	1	1
	Langkah	250	0.5	0.5	0.25	0.55	0.25

lokasi (rata-rata, median) dan penyebaran (standar deviasi, perbedaan rata-rata ab-solusi) ringkasan statistik pada residual dengan seperangkat uji parameter yang diketahui.

3 SPEKTRUM SINTETIS

Seperti yang telah disebutkan pada Bagian 1, teknik pembelajaran mesin telah diterapkan pada spektrum bintang di masa lalu dengan menggunakan data sintetis untuk pelatihan dan pengujian (Bailer-Jones 2000). Spektrum sintetis memberikan aplikasi yang unik untuk mengevaluasi model StarNet, karena semua detail spektrum diketahui secara apriori, dan S/N serta daerah panjang gelombang dapat divariasikan. Karena kami akan mengevaluasi StarNet pada set data yang diamati APOGEE, kami telah menerapkan StarNet pada spektrum sintetis yang dihasilkan oleh kolaborasi APOGEE.

3.1 Pelatihan dan pengujian StarNet dengan spektrum APOGEE ASSET

Spektrum sintetis yang digunakan oleh konsorsium APOGEE dihasilkan dengan menggunakan model atmosfer MARCS dan ATLAS9, seperti dijelaskan dalam Me´sza´ros dkk. (2012), dan kode transfer radiasi 'ASSET' (Koesterke dkk., 2008). Spektrum sintetis ini dinormalisasi secara konvergen dengan cara yang sama seperti spektrum APOGEE yang diamati untuk memfasilitasi kecocokan yang lebih dekat antara set data sintetis dan data yang disajikan. Disediakan dalam kisi-kisi spektral 6D yang tersedia untuk umum yang dikompresi dengan Analisis Komponen Utama (lihat Tabel 1 untuk distribusi parameter), kami menggunakan spektrum sintetis ini sebagai pengujian pertama StarNet. Untuk mengambil sampel spektrum pada lokasi yang diinginkan di dalam kisi sintetis, kami menggunakan rutinitas interpolasi orde tiga antara spektrum pada titik-titik kisi yang ada.

Dalam semua contoh pelatihan StarNet pada data sintetis, kami menambahkan derau Gaussian untuk mencocokkan S/N≈ 20 hingga spektrum tanpa derau. Setiap spektrum digunakan beberapa kali dalam proses pelatihan tertentu
(meskipun hanya sekali per iterasi pelatihan) dan oleh karena itu berbeda jumlah noise ditambahkan dengan setiap iterasi untuk meniru

perilaku beberapa kunjungan ke satu objek dalam survei APOGEE. Metode ini juga berkontribusi dalam menggeneralisasi kemampuan prediksi StarNet pada spektrum S/N yang lebih rendah.

Sebagai tes pertama, kami menghasilkan satu set data yang terdiri dari 300.000 spektrum sintetis melalui pengambilan sampel acak dari parameter bintang dalam batas-batas grid ASSET. Dari spektrum ini, 260.000 dipilih secara acak sebagai set referensi. Sebagian dari jumlah ini (224.000 atau 86 persen dari
set referensi) digunakan untuk melatih StarNet. Sisa 36.000 spektrum dari set referensi digunakan untuk memvalidasi silang model

mengikuti setiap iterasi pelatihan.

40.000 spektrum yang tidak termasuk dalam set referensi digunakan sebagai set pengujian, dan residual antara prediksi StarNet dan parameter yang dihasilkan ditunjukkan pada . 2. Untuk ketiga prediksi
parameter bintang, varians dari distribusi residu berbanding terbalik dengan S/N. Pada [Fe/H] <− 1.9 dan S/N yang lebih rendah, ada tren yang berbeda di mana StarNet tampaknya memprediksi secara berlebihan

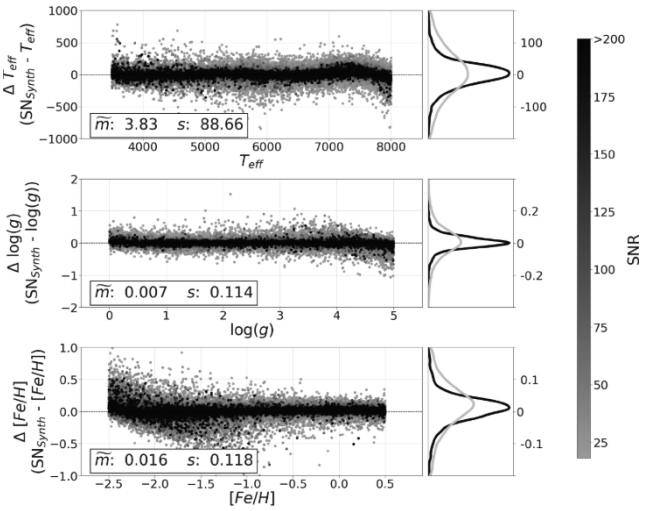

Gambar 2. Residual prediksi StarNet dengan parameter bintang yang dihasilkan untuk satu set uji coba 40.000 spektrum sintetik ASSET (Koesterke et al. 2008). StarNet dilatih dengan 224.000 spektrum sintetis yang diambil secara acak dari grid sintetis ASSET. Proyeksi distribusi residu ditampilkan di sebelah kanan (hitam untuk spektrum sintetis dengan S/N> 80, abu-abu untuk S/N< 60). Nilai median ($\tilde{m}$) dan standar deviasi (s) dihitung di setiap panel.

metalikitas. Di wilayah ini, fitur-fitur absorpsi tidak terlalu menonjol; oleh karena itu, noise secara efektif menyebabkan prediksi [Fe/H] StarNet serupa untuk semua bintang ini (yaitu [Fe/H] ≈− 2.2).

3.2 Prediksi dan presisi parameter bintang

Untuk mengevaluasi kesalahan dalam prediksi StarNet, perlu dipahami bagaimana output model dipengaruhi oleh ketidakpastian.
ikatan dalam spektrum input (***x***). Memperlakukan seluruh jaringan sebagai fungsi bernilai vektor $\boldsymbol{f}(\boldsymbol{x}, \boldsymbol{w}, \boldsymbol{b}) = (f_{T_{eff}}, f_{\log g}, f_{[Fe/H]})$, Jacobian dari model StarNet untuk sebuah bintang dan label bintang tertentu, *j*, diberikan oleh

$$\mathbf{J}(\boldsymbol{x}, \boldsymbol{w}, \boldsymbol{b}) = \left(\frac{\partial f_i}{\partial x_1}, \ldots, \frac{\partial f_i}{\partial x_{(n)}}\right)(\boldsymbol{x}, \boldsymbol{w}, \boldsymbol{b}).$$

Di sini, kami mengasumsikan bahwa setiap spektrum disertai dengan spektrum galat yang berkorelasi, $\boldsymbol{e}_x$. Mengalikan spektrum galat dengan Jacobian spektrum tersebut menghasilkan perkiraan ketidakpastian statistik, σ_{prop}, dari prediksi keluaran untuk setiap parameter bintang yang dihitung sebagai hasil kali:

$$\sigma^2_{\substack{alat\\perag\\a}} \approx \mathbf{J}^2 \boldsymbol{e}_x{}^2.$$

Selain membatasi perkiraan kami pada domain kesalahan yang kecil, kami tidak menghitung kesalahan dari bobot model StarNet CNN untuk alasan praktis. Untuk mengkompensasi defisit ini, intrinsik empiris, $\sigma_{(int)}$, diturunkan dari data uji sintetis, yang kemudian ditambahkan dalam kuadratur - berdasarkan elemen - dengan ketidakpastian yang disebarkan. Hal ini memberikan estimasi ketidakpastian total:

$$\sigma = \sqrt{\sigma^2_{\substack{alat\\perag\\a}} + \sigma^2_{int}}$$

Suku hamburan intrinsik sedikit bergantung pada wilayah ruang parameter tempat parameter yang diprediksi berada, yang mencerminkan kapasitas model fisis untuk mencocokkan fitur spektrum yang diamati. Sebagai contoh, suku hamburan intrinsik ini akan lebih besar untuk bintang-bintang yang diprediksi memiliki logam yang rendah dibanding bintang-bintang yang ternyata kaya akan logam (lihat Gbr. 2). Oleh karena itu, kami menurunkan istilah sebaran ini dalam bentuk bin, dalam rentang yang sama dengan kisi sintetik ASSET

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

Tabel 2. Pemotongan yang diterapkan pada APOGEE DR13 untuk set pelatihan dan pengujian.

Potong	Kunjungi spektrum		Spektrum gabungan
Tidak ada luka	559 484		143 482
BENDERA ASPCAP	327 594		92 983
BENDERA BINTANG	142 875		45 474
4000 K< $_{T\,(eff)}$ <5500 K	127 357		39 017
$_{vscatter}$ <1 km s^{-1}	120 879		37 311
[Fe/H] >− 3	120 879		37 311
log(*g*)! =−9999	113 956		35 591
SNR Gabungan> 200	53 135		Tidak berlaku
Partisi ke dalam set referensi dan set pengujian	Set pelatihan	Set validasi silang	Set uji
	41 000	3784	21 037

ditemukan pada Tabel 1: untuk T_{eff}, log *g*, dan [Fe/H], ukuran bin adalah 450 K,
0,5 dex, dan 0,3 dex, masing-masing.

4 STARNET APPLICAT ION KE SPEKTRUM APOGEE

Survei APOGEE telah dilakukan di Teleskop Sloan Foun- dation 2,5 m di New Mexico, dan mencakup rentang panjang gelombang 15-1,7 μm pada pita H, dengan resolusi spektral *R* =
22 500. Target ditinjau kembali beberapa kali hingga S/N≥ 100 tercapai (Majewski et al. 2017). Semua kunjungan diproses dengan menggunakan data reduksi.
pipa ke 1D dan dikalibrasi panjang gelombangnya sebelum digabungkan. Kunjungan individu, spektrum gabungan yang tidak dinormalisasi, dan spektrum gabungan yang dinormalisasi semuanya dicatat ke dalam basis data APOGEE yang tersedia untuk umum (Nidever et al. 2015).

APOGEE Stellar Parameters and Chemical Abundances Pipeline (ASPCAP) adalah alat pipa reduksi data untuk produk sains tingkat lanjut. Pipeline ini mengandalkan algoritma fitting kuadrat terkecil non-linear FERRE (Garcia-Pe´rez et al. 2016, yang membandingkan spektrum yang diamati dengan kisi-kisi spektrum sintetis yang dibuat dari atmosfer model bintang yang terperinci dan perhitungan transfer garis radiatif. Untuk DR12, kisi sintetis ini adalah kisi ASSET yang digunakan untuk pelatihan di bagian sebelumnya. Proses fitting mengestimasi parameter bintang (T_{eff}, log *g*, [Fe/H]) dan kelimpahan untuk 15 elemen yang berbeda (C, N, O, Na, Mg, Al, Si, S, K, Ca, Ti, V, Mn, Fe, dan Ni). Hasil ini selanjutnya dikalibrasi dengan perbandingan parameter bintang dari analisis spektral optik bintang-bintang dari berbagai gugus bintang (Cunha dkk. 2015; Me´sza´ros dkk. 2015); lihat Lampiran untuk lebih jelasnya.

4.1 Pra-pemrosesan data masukan

Sebagai uji coba, StarNet juga dilatih menggunakan spektrum yang diamati APOGEE dan parameter bintang ASPCAP DR13 (lihat Albareti et al. 2017). Spektrum galat APOGEE dan estimasi galat dari ASPCAP tidak disertakan sebagai bagian dari set referensi. Hal ini secara efektif membatasi akurasi StarNet pada parameter set referensi. Untuk meminimalisir penyebaran kesalahan ASPCAP dalam StarNet
Untuk mendapatkan hasil yang lebih baik, kami membatasi rentang data kami gunakan. Sebagai contoh, Holtzman dkk. (2015) memperingatkan agar tidak menggunakan bintang-bintang yang lebih dingin dari T_{eff}= 4000 K, di mana model-model yang ada kurang dapat dipastikan, serta bintang-bintang yang lebih panas di mana
fitur spektral kurang terdefinisi dengan baik. Karena alasan-alasan ini, kumpulan data kami direduksi menjadi bintang-bintang di antara 4000 K≤ $_{T(eff)}$≤ 5500 K.

Tim APOGEE juga telah menandai bintang-bintang dan kunjungan tertentu untuk
berbagai alasan lainnya. Bintang-bintang dari set data DR13 yang memiliki STARFLAG atau ASPCAPFLAG telah dihapus dari set data, termasuk bintang-bintang yang terkontaminasi oleh persistensi (lihat Nidever et al. 2015; Jahandar et al. 2017), bintang-bintang yang ditandai karena memiliki tetangga yang terang, atau memiliki estimasi parameter di dekat pa-
rameter tepi kisi-kisi model sintetik. Lebih jauh lagi, bintang-bintang dengan [Fe/H] <− 3 telah dihilangkan, atau yang memiliki sebaran kecepatan radial, v $_{(sebaran)}$, lebih besar dari 1 km $s^{-(1)}$. Spektrum dengan v $_{sebaran}$ yang tinggi kemungkinan adalah
bintang biner (Nidever et al. 2015), dengan spektrum yang berpotensi menduplikasi
garis.

Menerapkan pembatasan ini pada *set referensi* memungkinkan NN untuk dilatih pada set data yang lebih bersih dan belajar dari parameter bintang yang lebih akurat, sementara menempatkan pembatasan ini pada *set uji* adalah upaya untuk memaksimalkan validitas parameter bintang ASPCAP yang akan digunakan ketika membandingkan dengan prediksi StarNet. Semua pemotongan pada set data APOGEE dirangkum dalam Tabel 2.

Selain batasan yang disebutkan di atas, set referensi hanya mencakup spektrum kunjungan individual dari bintang-bintang yang spektrum gabungannya memiliki S/N> 200. Ketepatan parameter bintang ASPCAP diketahui menurun pada S/N yang lebih rendah (Ness dkk. 2015; Casey dkk. 2016). Namun, menggunakan spektrum gabungan S/N tinggi sebagai input pelatihan menghasilkan overfitting pada model (lihat Lampiran A) untuk spektrum dengan S/N tinggi. Untuk mengimbangi masalah ini, StarNet dilatih dengan spektrum kunjungan individual, sambil menggunakan parameter bintang yang diperoleh dari spektrum gabungan. Langkah ini memungkinkan model untuk dilatih pada spektrum S/N yang lebih rendah dengan parameter presisi tinggi. Membatasi sampel pelatihan kami agar berisi parameter bintang dari spektrum S/N tinggi juga praktis: saat ini StarNet tidak dapat membobotkan spektrum input sesuai dengan sifat noise spektrum selama pelatihan. Ketika menggabungkan berbagai set data, yang akan kami bahas dalam pekerjaan di masa depan, hal ini mungkin menjadi lebih penting, tetapi kurang relevan untuk analisis saat ini.

Tahap terakhir dari pra-pemrosesan data adalah menormalkan spektrum. Baik Cannon 2 (Casey et al. 2016) maupun ASPCAP telah menerapkan teknik normalisasi kontinum independen; sebagai tambahan, spektrum APOGEE DR13 dinormalisasi lebih lanjut pada daerah spektral tertentu. Spektrum sintetis ASSET juga dinormalisasi secara simultan untuk memfasilitasi pencocokan yang tepat dengan data. Telah disarankan (misalnya Casey et al. 2016) bahwa teknik normalisasi kontinum ASPCAP menghasilkan ketergantungan S/N. Ini adalah keterbatasan potensial dari StarNet ketika telah dilatih pada spektrum sintetis, karena spektrum ini dinormalisasi oleh ASPCAP tanpa penambahan noise sebelumnya. Setiap non-linearitas dalam nor- malisasi kontinum akan dikeluarkan dari kumpulan data spektrum sintetis. Jika normalisasi yang tidak konsisten ini memang menjadi masalah, hal ini dapat menimbulkan ketidakcocokan antara spektrum sintetik dan spektrum S/N APOGEE yang rendah dengan parameter bintang yang sama, sehingga menghasilkan estimasi parameter bintang yang salah.

Potensi bias normalisasi kontinum ini memotivasi kami untuk mengadopsi metode normalisasi yang sederhana dan linier di StarNet; untuk

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

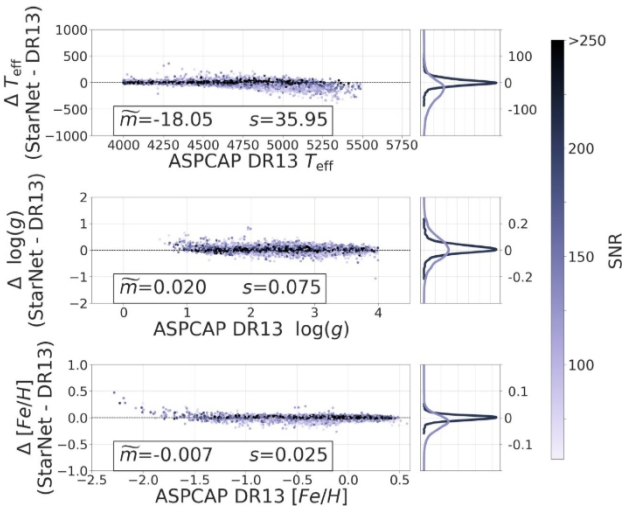

Gambar 3. Residual dari prediksi StarNet dan parameter ASPCAP untuk satu set uji coba dari 21.037 spektrum gabungan pada berbagai macam S/N. StarNet dilatih pada 41.000 spektrum kunjungan individu dari set data APOGEE DR13. Ketika S/N menurun, penyimpangan kecil terlihat untuk bintang-bintang lebih panas, bintang-bintang di ujung bawah kisaran gravitasi permukaan, dan bintang-bintang yang paling miskin logam, yang kemungkinan besar disebabkan oleh bias ukuran sampel dalam set pelatihan. Proyeksi distribusi residu ditampilkan di sebelah kanan (ungu tua untuk spektrum dengan S/N> 200, ungu muda untuk S/N< 100).

Catatan. Nilai median ($\tilde{m}$) dan deviasi standar (s) dihitung pada setiap panel, seperti pada Gbr. 2.

pelatihan dan pengujian pada spektrum APOGEE, spektrum dibagi menjadi chip biru, hijau, dan merah, dan setiap chip dibagi berdasarkan nilai fluks mediannya. Ketiga chip tersebut kemudian digabungkan untuk membuat satu vektor spektrum. Mengingat bahwa prosedur normalisasi biasanya tidak memerlukan informasi eksternal, pendekatan sederhana kami juga menguji kemampuan jaringan dibandingkan dengan penghilangan sinyal secara fisik. Namun, analisis lebih lanjut diperlukan untuk menentukan dampak penuh dari normalisasi kontinum dalam pendekatan NN ini.

4.2 Pelatihan dan pengujian StarNet dengan spektrum APOGEE

StarNet telah dilatih dan diuji pada parameter bintang ASPCAP (T_{eff}, log g, [Fe/H]) yang sesuai dengan spektrum kunjungan individu dan spektrum gabungan. Seperti yang telah dibahas sebelumnya, ini termasuk bintang-bintang dari set data APOGEE DR13 dengan yang tercantum pada Tabel 2. Terdapat 17.149 bintang dengan S/N> 200 yang memenuhi persyaratan ini, dimana 2651 di antaranya digunakan sebagai bagian dari set pengujian, dan 14.498 bintang (mengandung 44.784 kunjungan individu) digunakan sebagai set referensi StarNet. Jumlah ini sedikit kurang dari 10 persen dari total set data APOGEE DR13. Sebagian dari kunjungan individu ini (41.000 atau 92 persen dari set referensi) dipilih secara acak untuk set pelatihan. Sisanya, 3784 spektrum kunjungan digunakan untuk memvalidasi silang model StarNet setelah setiap proposisi maju selama pelatihan. Tidak ada penyimpangan yang signifikan yang ditemukan antara pemilihan acak untuk sampel pelatihan dan validasi silang.

Setelah dilatih, StarNet diterapkan pada set pengujian yang berisi spektrum gabungan S/N tinggi dan rendah. Prediksi StarNet dibandingkan dengan parameter ASPCAP pada . 3. Untuk spektrum S/N tinggi, prediksi StarNet menunjukkan kesesuaian yang sangat baik dengan hasil ASPCAP DR13. Untuk spektrum S/N yang lebih rendah, terdapat lebih banyak dan lebih besar penyimpangan antara StarNet dan DR13. Sebagai contoh, pada suhu tinggi ($T_{(eff)}$>5000 K), StarNet memprediksi suhu efektif yang lebih rendah daripada DR13. Kualitas prediksi model tergantung pada jumlah bintang dalam himpunan pelatihan yang menjangkau ruang parameter himpunan uji; oleh karena itu, kami menyarankan bahwa penyimpangan ini disebabkan oleh

jumlah bintang dengan $T_{(eff)}$>5000 K (~ 4 persen) dalam himpunan referensi kami. Demikian pula, hanya ada sedikit bintang dengan metalitas rendah,

[Fe/H]< − 1.5 (~ 0.2 persen dari set referensi), dan oleh karena itu menerapkan StarNet pada bintang-bintang yang paling miskin logam juga menghasilkan

penyimpangan dari hasil DR13. Bias ukuran sampel, seperti yang terlihat di dua wilayah ini, memperkuat kebutuhan akan set pelatihan yang besar untuk NN yang mendalam seperti StarNet.

Sumber kesalahan potensial lainnya dalam prediksi pada suhu tinggi dan logam rendah terletak pada spektrum itu sendiri. Di wilayah ini, fitur spektral lebih lemah, oleh karena itu NN akan berjuang untuk menemukan fitur yang paling penting selama pelatihan. Demikian pula, parameter yang ditentukan oleh ASPCAP akan memiliki ketidakpastian intrinsik yang lebih besar. Lebih jauh lagi, efek ini dapat diperkuat ketika menguji pada spektrum S/N yang lebih rendah.

Setelah pelatihan, StarNet kemudian diterapkan pada 148.724 bintang dalam basis data APOGEE DR13. Langkah inferensi akhir ini sangat cepat: membutuhkan waktu sekitar 1 menit dari waktu CPU untuk seluruh kumpulan data. Singkatnya waktu yang dibutuhkan untuk membuat prediksi ini merupakan kemajuan besar untuk pengurangan data yang cepat dari survei spektral yang besar.

Prediksi StarNet untuk 99.211 spektrum ditunjukkan pada Gambar 4, di mana bintang-bintang dengan nilai ASPCAP T_{eff}, log g, atau [Fe/H] dari− 9999 dipindahkan bersama dengan bintang-bintang yang diduga sebagai bintang katai M (lihat

Bagian 5.2). Prediksi StarNet dibandingkan dengan isokron bintang untuk menunjukkan tren yang diharapkan dalam hubungan parameter; empat

isokron dengan metalitas yang berbeda ([Fe/H]= 0,25,− 0,25,− 0,75,

dan− 1.75) dihasilkan dari Dartmouth Stellar Evolution

Database (Dotter dkk. 2008), dengan usia 5 Gyr dan [α/Fe=

0. Gbr. 4 juga menunjukkan kumpulan referensi StarNet yang terdiri dari 14.498 bintang, tinggi

menyala untuk menunjukkan penyebaran kelimpahannya di seluruh ruang parameter.

Untuk menganalisis konsistensi model StarNet, prediksi dibuat untuk spektrum kunjungan individu dan spektrum gabungan untuk objek yang sama. Target dengan empat atau lebih kunjungan individu dipilih untuk pengujian ini, dan perbedaan dalam residu dihitung. Untuk setiap bin parameter bintang, nilai rata-rata untuk 100 objek ditunjukkan pada Gambar 5 (panel kiri), sedangkan untuk setiap bin S/N ada 230 objek (panel kanan). Kesalahan yang disebarkan dan total kesalahan yang ditampilkan dibahas pada Bagian 3.2. Ketika membandingkan pra-diksi StarNet untuk kunjungan individu dengan spektrum gabungan, hasilnya cukup konsisten di sebagian besar ruang parameter, meskipun seperti yang telah dibahas sebelumnya, ada peningkatan yang nyata

dalam penyimpangan pada logam yang lebih rendah ([Fe/H] <− 1.2 dex)

dan

suhu yang lebih tinggi (T_{eff}> 5100 K). Juga seperti yang diharapkan, sebaran meningkat pada S/N yang lebih rendah, meskipun hanya sedikit hingga S/N . 60. Bahkan pada nilai terendah (S/N~ 15), hasilnya cukup konsisten. Kemampuan untuk memprediksi dengan baik pada spektrum S/N yang lebih rendah sebagian besar disebabkan oleh

fakta bahwa StarNet dilatih berdasarkan kunjungan individual - bukan hanya spektrum gabungan - dengan parameter bintang yang sangat valid.

Tren yang terlihat pada residual antara prediksi untuk kunjungan individual dan spektrum gabungan (yaitu peningkatan sebaran pada logam yang lebih rendah dan S/N yang lebih rendah) juga tercermin pada kesalahan yang disebarkan StarNet (lihat Bagian 3.2), yang juga ditunjukkan pada Gbr. 5. Hal ini memberikan keyakinan bahwa metode propagasi kesalahan yang digunakan memberikan estimasi yang memadai terhadap ketidakpastian dalam prediksi StarNet.

4.3 Pemilihan model

Arsitektur deep learning, seperti StarNet, biasanya melibatkan eksperimentasi dan penyetelan hiper-parameter untuk menyatu dengan model yang memadai. Beberapa parameter hiper ini meliputi

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

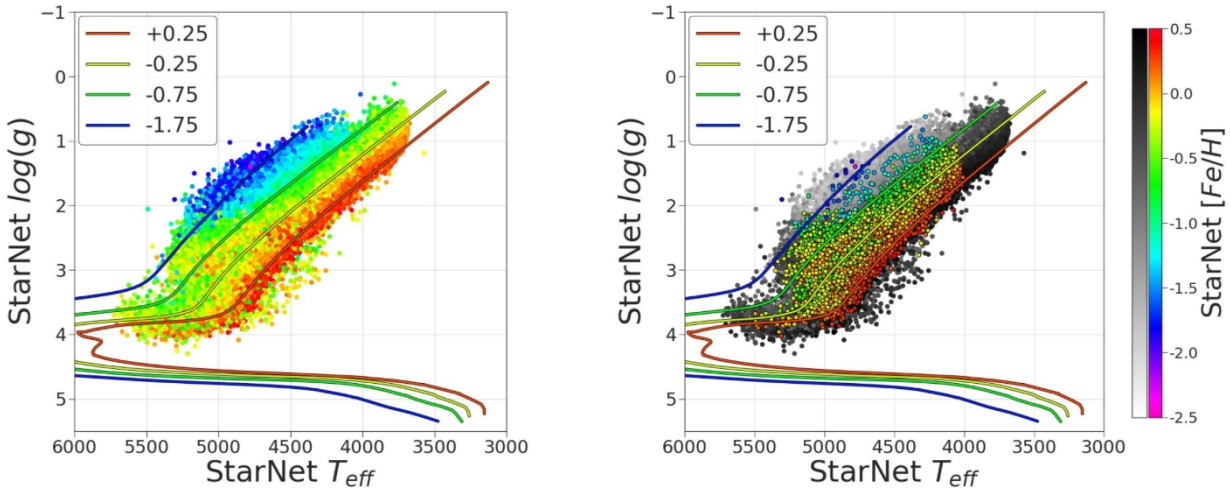

Gambar 4. Panel sebelah kiri: parameter bintang dari StarNet untuk 99.211 bintang, menunjukkan parameter log g terhadap $T_{\rm eff}$ pada rentang [Fe/H] yang luas (lihat bilah warna). Panel kanan: set referensi StarNet yang terdiri dari 14.498 bintang disorot di atas sampel penuh 99.211 bintang (berwarna abu-abu). Isokron bintang ditampilkan pada kedua panel (dari Dotter et al. 2008), dengan usia 5 Gyr dan nilai [Fe/H] yang ditemukan di sudut kiri atas (sesuai dengan bilah warna).

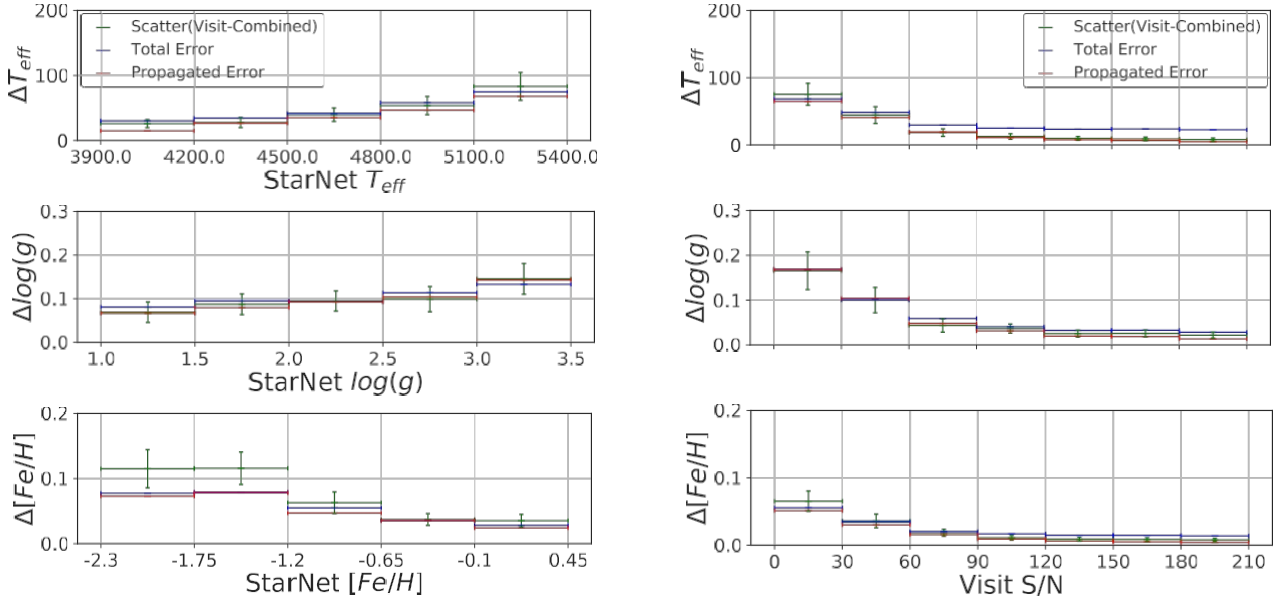

Gambar 5. Perbandingan prediksi StarNet pada kunjungan individu dengan prediksi untuk spektrum gabungan yang sesuai. Panel sebelah kiri: perbandingan dilakukan pada ruang parameter, di mana setiap bin parameter mencakup 100 spektrum yang dipilih secara acak. Penyimpangan terbesar ditemukan pada logam yang lebih rendah dan suhu yang lebih tinggi. Panel sebelah kanan: perbandingan dibuat berdasarkan S/N dari masing-masing kunjungan, di mana setiap bin S/N berisi 230 spektrum. Pada kedua plot, 'Scatter (Visit-Combined)' adalah deviasi standar pada residual antara prediksi untuk kunjungan individual dan spektrum gabungan untuk objek dengan lebih dari empat kunjungan individual. 'Kesalahan yang Dipropagasi' adalah istilah kesalahan karena spektrum kesalahan, sedangkan 'Kesalahan Total' adalah kesalahan yang dipropagasi dan istilah 'Sebaran Intrinsik' (lihat Bagian 3.2) yang ditambahkan dalam kuadratur. StarNet dilatih dengan 41.000 spektrum kunjungan individu dari set data ASPCAP DR13.

jumlah filter di setiap lapisan konvolusi; panjang filter yang dilingkarkan pada input di setiap lapisan konvolusi; jumlah node koneksi di setiap lapisan yang terhubung penuh; ukuran jendela pooling di lapisan maxpooling (jumlah input yang dibandingkan satu sama lain untuk menemukan nilai maksimum); dan laju pembelajaran dari pengatur waktu gradient descent. Pemilihan akhir hyper-parameter dilakukan secara otomatis sebagai berikut: untuk memilih arsitektur model yang optimal, optimasi hyper-parameter dijalankan dalam dua tahap. Pada tahap pertama, jumlah lapisan konvolusi, lapisan yang terhubung penuh, filter, dan node divariasikan secara acak, bersama dengan panjang filter, ukuran jendela pooling, dan laju pembelajaran. Hal ini memungkinkan pengoptimal untuk menguji berbagai kombinasi jumlah lapisan konvolusi dan lapisan terhubung penuh.

menghubungkan lapisan-lapisan dengan berbagai hiper-parameter lainnya untuk memastikan bahwa setiap kombinasi dapat mencapai potensi prediksi maksimum. Set pelatihan dan validasi silang yang sama (seperti yang dijelaskan pada Bagian 4.1) digunakan selama pelatihan model-model ini, dan set pengujian yang sama (dibahas pada Bagian 4.2) digunakan untuk menguji setiap model. Metrik yang digunakan untuk perbandingan model adalah MSE antara parameter target dan prediksi. Agar setiap parameter memiliki bobot yang sama, parameter dinormalisasi agar memiliki rata-rata dan varians unit yang sama. Contoh model berkinerja terbaik, yang dievaluasi untuk setiap kombinasi lapisan, ditunjukkan pada Gbr. 6.

Ditemukan bahwa peningkatan jumlah lapisan meningkatkan prediksi model, tetapi ada penurunan kinerja ketika menggabungkan dua lapisan konvolusi dengan dua lapisan yang terhubung penuh.

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

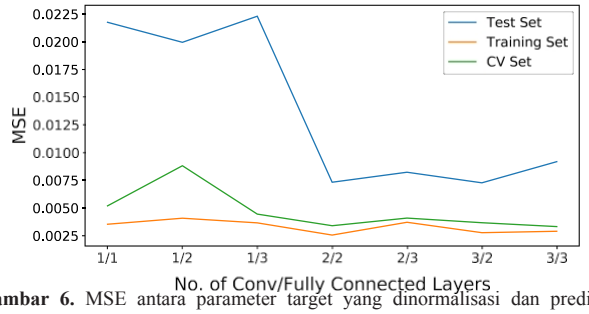

Gambar 6. MSE antara parameter target yang dinormalisasi dan prediksi StarNet diplotkan terhadap kombinasi yang berbeda dari lapisan konvolusi dan lapisan yang terhubung penuh. Hasil ini digunakan untuk membantu memilih arsitektur model StarNet.

lapisan. Penambahan lebih banyak lapisan pada arsitektur ini tidak secara jelas meningkatkan hasil prediksi, sementara lapisan yang lebih sedikit menyebabkan MSE yang jauh lebih buruk.

Optimasi hiper-parameter kedua kemudian dimulai, di mana jumlah lapisan konvolusi dan lapisan yang terhubung penuh ditetapkan masing-masing dua, sementara hiper-parameter yang tersisa divariasikan dan dioptimasi menggunakan Tree-structured Parzen Estimator (TPE, Bergstra dkk., 2011). Model yang dipilih oleh tahap kedua dari optimasi hyper-parameter ini serupa dengan yang ditunjukkan pada Gambar 1, dan model ini digunakan sebagai titik awal untuk pemilihan arsitektur model. Perubahan kecil dilakukan untuk menemukan kemungkinan perbaikan hingga arsitektur model StarNet bekerja secara konsisten dengan hasil yang memadai.

Meskipun model yang lebih sederhana dapat berkinerja sebanding dengan arsitektur StarNet ketika dilatih dengan data sintetis, diputuskan bahwa arsitektur model tunggal harus digunakan untuk melatih data sintetis dan spektrum APOGEE.

Studi sebelumnya menemukan bahwa penerapan NN pada spektrum bintang hanya membutuhkan paling banyak dua lapisan tersembunyi dengan jumlah node yang lebih sedikit daripada jumlah yang digunakan di StarNet (Bailer-Jones 2000), tetapi ini diterapkan pada set data yang jauh lebih kecil. Metode pembelajaran mesin saat ini - bersama dengan set data yang besar - memungkinkan model yang lebih kompleks untuk meningkatkan kinerja sambil tetap menghindari overfitting. Lapisan max pooling mengurangi derajat kebebasan model dengan meminimalkan dampak bobot yang tidak perlu dan oleh karena itu menyederhanakan fungsi model. Untuk mempercepat konvergensi untuk kecocokan model StarNet, kami menggunakan inisialisasi bobot *He Normal* (He et al. 2015), juga memungkinkan konvergensi model yang lebih dalam dan pada akhirnya memungkinkan NN untuk menemukan fitur yang lebih kompleks. Singkatnya, inisialisasi *He Normal*, aktivasi Rectified Linear Unit (ReLU), dan pengoptimal ADAM (lihat Lampiran A) memungkinkan model yang lebih dalam mencapai konvergensi dengan lebih mudah dan dengan yang lebih cepat, sementara lapisan max pooling menyederhanakan kerumitan peringkat model. Penggunaan set validasi silang adalah teknik lain yang diimplementasikan dalam StarNet untuk mengurangi overfitting. Teknik dan metode ini dijelaskan lebih lanjut dalam Lampiran A.

4.4 Perbandingan dengan Meriam

Cannon (Ness et al. 2015) adalah model generatif berbasis data yang memiliki keterbatasan yang sama dengan pendekatan pembelajaran yang diawasi,
yaitu keduanya bergantung pada kumpulan data referensi. Tidak seperti StarNet, pendekatan generatif menggunakan parameter bintang sebagai input dan spektrum sebagai output selama pelatihan. Cannon menggunakan fungsi polinomial kuadratik untuk menerjemahkan parameter bintang ke dalam spektrum, dan koefisien fungsi yang paling sesuai ditemukan melalui fitting kuadrat terkecil. Selama tahap pengujian, parameter bintang ditentukan dengan langkah regresi lainnya, di mana parameter bintang divariasikan hingga menghasilkan spektrum yang paling cocok dengan spektrum yang diamati.

Pada awalnya, Cannon dilatih menggunakan spektrum gabungan APOGEE DR10 (Me´sza´ros et al. 2013) yang terdiri dari 542 bintang di 19 gugus. Jumlah contoh yang dilatih jauh lebih sedikit daripada yang digunakan StarNet dari DR13namun Cannon mampu memprediksi parameter bintang untuk spektrum DR10 dengan sangat baik. Untuk membandingkan kedua teknik tersebut, kami melatih arsitektur StarNet yang sama, yang diberi nama StarNet$_{C1}$, pada set data yang sama, yaitu 542 bintang dari DR10. StarNet$_{C1}$kemudian diterapkan pada 29.891 spektrum gabungan yang memiliki prediksi ASPCAP dan Cannon untuk parameter bintang. Kedua hasil tersebut dibandingkan pada Gambar 7, di mana keterbatasan model StarNet$_{C1}$ terlihat jelas. Metode pembelajaran mesin yang digunakan untuk StarNet membutuhkan sampel pelatihan yang *besar* yang menjangkau ruang parameter yang luas. Pelatihan pada 542 spektrum gabungan tidak mencakup rentang parameter yang cukup pada akumulasi S/N yang sesuai dengan StarNet CNN yang kompleks. Hal ini juga dapat dilihat pada residual yang besar ketika membandingkan prediksi StarNet$_{C1}$ dan parameter ASPCAP DR10. Prediksi untuk spektrum S/N rendah menunjukkan sebaran yang paling signifikan.

Persyaratan set pelatihan yang besar yang cukup mewakili set pengujian adalah batasan dari banyak metode deep learning, seperti

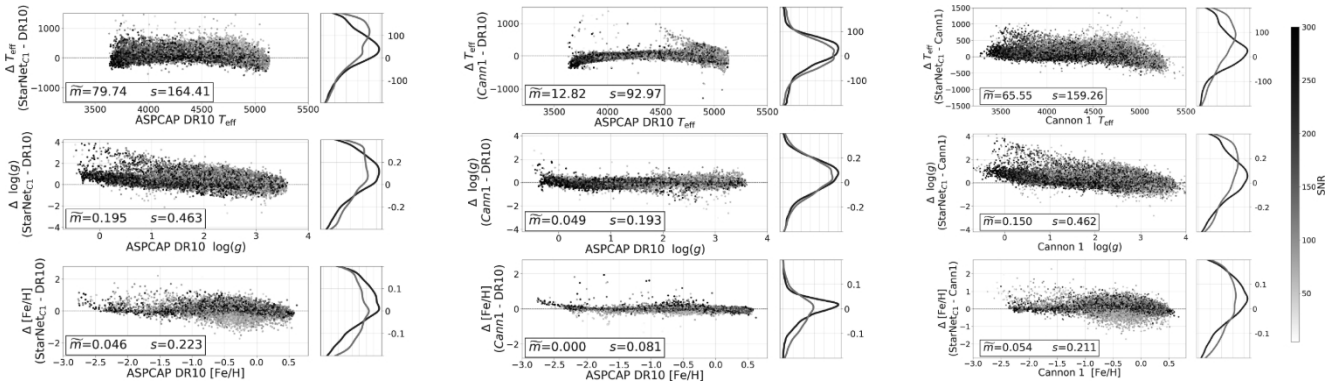

Gambar 7. Perbandingan hasil StarNet$_{C1}$ dengan ASPCAP (panel kiri) dan hasil StarNet$_{(C)1}$ dengan Cannon 1 (panel kanan), serta perbandingan antara Cannon 1 dan ASPCAP (panel tengah). StarNet$_{C1}$ dilatih dengan spektrum gabungan APOGEE DR10 dari 542 bintang yang sama dengan yang digunakan oleh Cannon 1 untuk pelatihan. Set uji coba mencakup spektrum gabungan DR10 yang memiliki prediksi ASPCAP dan Cannon 1. Nilai median (m˜) dan standar deviasi (s) dihitung pada setiap panel, seperti pada Gambar 2. (Perhatikan bahwa rentang pada sumbu plot berbeda dengan plot lainnya dalam makalah ini).

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

Tabel 3. Perbandingan hasil StarNet$_{C(2)}$) dan Can- non 2 untuk satu set pengujian 85.341 spektrum gabungan dari APOGEE DR12. Metrik yang digunakan adalah MAE dan RMSE, sehubungan dengan bintang yang sama.

Metrik	Parameter	StarNet $_{C2}$	Meriam 2
	Teff	31.2	46.8
MAE	log *g*	0.053	0.066
	[Fe/H]	0.025	0.036
	Teff	51.2	71.6
RMSE	log *g*	0.081	0.102
	[Fe/H]	0.040	0.053

StarNet. Namun, ketika set data yang lebih besar tersedia, maka metode ini dapat menjadi sangat efektif, seperti yang dibahas pada bagian selanjutnya.

4.5 Perbandingan dengan Cannon 2

The Cannon 2 (Casey dkk. 2016) merupakan kelanjutan dari proyek Cannon. Selain tiga parameter bintang yang diprediksi oleh Cannon, The Cannon 2 juga memprediksi 14 kelimpahan kimia tambahan. Cannon 2 juga dilatih untuk melakukan spektrum kunjungan individual, tapi ia melatih lebih banyak bintang daripada Cannon. Selain itu, Cannon 2 menambahkan istilah regularisasi dalam fungsi pada saat pelatihan, untuk mengurangi kemungkinan model yang terlalu cocok dengan data pelatihan.

Set latihan untuk Cannon 2 terdiri dari bintang-bintang dengan 200< S/N< 300, [Fe/H] >− 3, [X/Fe]< 2, [α/Fe] >− 0.1, [v/Fe]> − 0.6, $v_{sebaran}$ < 1 km s^{-1}, dan mengecualikan target yang ditandai dengan `ASPCAPFLAG`. Pemotongan ini menghilangkan bintang-bintang di dekat tepi grid model sintetis, bersama dengan sumber kesalahan lain yang mengakibatkan penentuan parameter ASPCAP yang buruk. Namun, model ini tidak memperhitungkan spektrum yang ditandai dengan persistensi. Set pelatihan Cannon 2 terdiri dari kunjungan dari 12.681 bintang.

Untuk membuat perbandingan yang memadai antara kedua model, StarNet$_{C2}$ dilatih pada 39.098 kunjungan dari 12.681 bintang yang memenuhi batasan yang sama yang ditetapkan oleh set pelatihan Cannon 2, dari APOGEE DR12 (Holtzman dkk. 2015). Satu set uji yang terdiri dari 85.341 spektrum gabungan dengan 4000 K< $_{T(eff)}$)<5500 K dan log *g*< 3.9 diadopsi, dengan batasan yang sama dengan set uji Cannon 2.

Kami mengumpulkan root-mean-square error (RMSE) dan mean absolute error (MAE) untuk set pengujian yang sama untuk Cannon 2 dan StarNet$_{C2}$ pada Tabel 3. Hal ini menegaskan inspeksi visual dari residual pada Gambar 8, bahwa StarNet$_{C(2)}$) mampu memprediksi lebih mendekati parameter bintang ASPCAP. Juga terlihat pada Gambar 8, StarNet$_{C2}$ berbeda dengan ASCAP pada logam yang lebih rendah dan temperatur yang lebih panas, ketika S/N spektrumnya lebih rendah. Efek ini juga terlihat pada prediksi Cannon 2. Bahkan, perbandingan StarNet$_{C2}$ dengan Cannon 2 menunjukkan bahwa efeknya lebih besar pada hasil Cannon 2.

4.6 Melatih StarNet dengan spektrum sintetis

Langkah penting berikutnya dalam pengembangan pendekatan NN untuk menganalisis spektrum bintang adalah untuk menunjukkan bahwa StarNet juga dapat memprediksi parameter bintang tanpa pipa eksternal. Pada bagian ini, kami menyajikan hasil parameter bintang untuk data APOGEE setelah melatih StarNet hanya pada spektrum sintetis. Tujuan kami adalah untuk menunjukkan bahwa StarNet dapat beroperasi sebagai pipeline pemrosesan data berdiri sendiri, menghasilkan basis data parameter bintang yang independen dan tidak bergantung pada hasil pipeline ASPCAP untuk pelatihan.

4.6.1 Celah sintetis

Perbedaan distribusi fitur antara spektrum sintetis dan spektrum yang diamati disebut sebagai celah *sintetis*. Untuk menyelidiki kelayakan pelatihan StarNet pada spektrum sintetis dan secara akurat memprediksi parameter dari spektrum yang diamati, perlu dipastikan bahwa celah sintetis relatif kecil. Karena setiap spektrum terdiri dari 7214 titik data atau mewakili sebuah titik dalam ruang 7214 dimensi, maka diharapkan spektrum sintetis dan spektrum yang diamati dengan parameter yang sama akan menempati wilayah yang sama dalam ruang ini jika kesenjangannya kecil. Memvisualisasikan ruang ini hanya dapat dilakukan melalui reduksi dimensi. Kami menggunakan t-Distributed Stochastic Neighbour Embedding (t-SNE; Maaten & Hinton 2008), sebuah teknik yang sering digunakan dalam pembelajaran mesin untuk menemukan kelompok data yang serupa dalam ruang dua dimensi (2D). Ruang 2D ini terdiri dari variabel sembarang - bukan parameter fisik bintang - yang dimaksudkan untuk berfungsi sebagai representasi dimensi yang lebih rendah dari spektrum untuk memfasilitasi visualisasi.

Subset dari 4000 spektrum APOGEE DR13 dengan S/N> 200 dan parameter ASPCAP yang diketahui dipilih secara acak, bersama dengan 4000 spektrum sintetis ASSET yang telah diinterpolasi dengan yang sama. Setelah menerapkan t-SNE, pemisahan yang berbeda dapat dilihat antara spektrum sintetis dan APOGEE (gambar kiri pada Gambar 9). Pemeriksaan spektrum yang tidak cocok menunjukkan bahwa terdapat nilai fluks nol pada rentang panjang gelombang di sepanjang spektrum, sebuah metode yang digunakan dalam

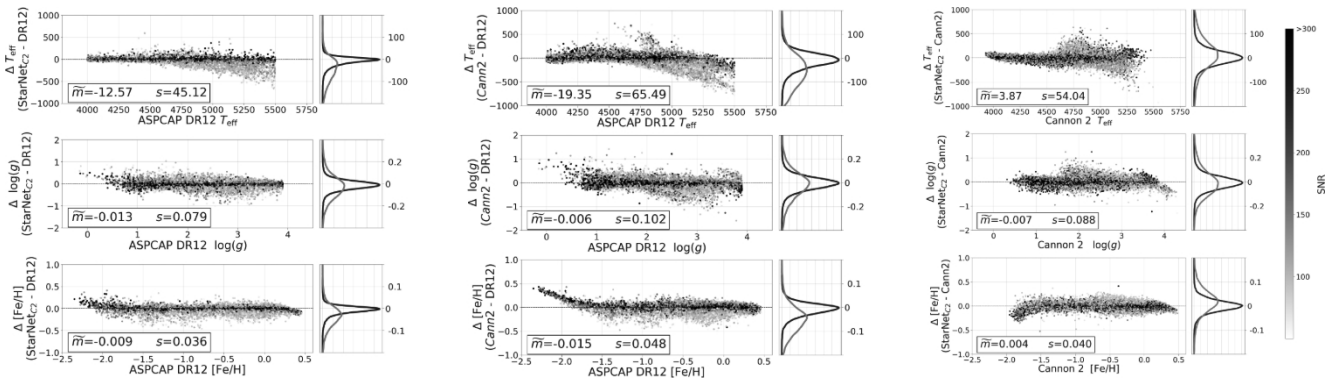

Gambar 8. Perbandingan hasil StarNet$_{C2}$ dengan ASPCAP (panel kiri) dan hasil StarNet$_{C2}$ dengan prediksi Cannon 2 (panel kanan), serta perbandingan antara Cannon 2 dan ASPCAP (panel tengah). Semua parameter didasarkan pada kumpulan data DR12. StarNet dilatih dengan kunjungan individual dari bintang-bintang yang serupa dengan yang digunakan untuk melatih Cannon 2. Set pengujian yang digunakan untuk membandingkan kedua metode ini juga serupa dengan yang digunakan oleh Cannon 2. Nilai median (m˜) dan standar deviasi (s) dihitung di setiap panel, seperti pada Gambar 2.

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

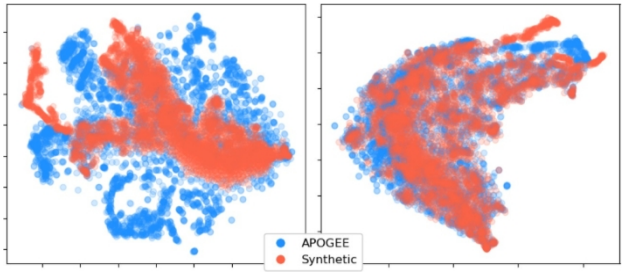

Gambar 9. Visualisasi t-SNE dari spektrum sintetik dan APOGEE sebelum substitusi fluks-nol melalui interpolasi tetangga terdekat (kiri) dan setelahnya (kanan).

pipeline APOGEE untuk menandai piksel yang buruk. Sayangnya, nilai-nilai ini tidak dapat disamarkan pada tahap pengujian dengan implementasi StarNet saat ini, sehingga interpolasi tetangga terdekat dilakukan untuk memperhalus nilai nol. Putaran t-SNE yang lain menunjukkan kesesuaian yang lebih dekat antara spektrum sintetik dan APOGEE (gambar kanan pada Gbr. 9). Nilai fluks nol untuk semua spektrum APOGEE ini diperbaiki sebelum memprediksi parameter bintangnya dalam pelatihan StarNet sub-sekuen dari spektrum sintetik.

Meskipun interpolasi nilai titik nol pada spektrum yang diamati menghasilkan prediksi yang lebih akurat, kami mengingatkan bahwa ini mungkin solusi yang ideal. Hal ini karena kami memodifikasi data dengan cara yang mungkin tidak menyerupai spektrum tanpa nilai titik nol. Metode alternatifnya adalah dengan menyuntikkan nilai titik nol secara artifisial pada spektrum sintetis selama pelatihan. Hal ini akan memungkinkan StarNet untuk mendistribusikan bobot secara lebih merata di seluruh spektrum, meniru proses pelatihan pada spektrum yang diamati. Kami mencatat bahwa hal ini tidak menjadi masalah ketika StarNet dilatih pada spektrum APOGEE asli yang secara inheren memiliki nilai fluks-nol.

4.6.2 Prediksi untuk spektrum APOGEE DR12

Setelah melatih StarNet dengan spektrum sintetis dari kode ASSET (seperti yang dijelaskan pada Bagian 3), kami menerapkannya pada satu set data yang terdiri dari 21.787 spektrum gabungan dari APOGEE DR12[1] dengan menggunakan batasan yang sama seperti yang terdapat pada Tabel 2. Kami membandingkan hasil kami dengan parameter ASPCAP DR12 (lihat Gambar 10), karena parameter tersebut juga ditentukan dengan menggunakan kisi spektral ASSET (tidak seperti hasil APOGEE DR13).

Distribusi residu serupa dengan yang terlihat pada Gambar 3, di mana StarNet dilatih pada spektrum APOGEE yang diamati. Menggunakan

Dengan menggunakan metode seperti yang dijelaskan pada Bagian 3.2, istilah kesalahan hamburan intrinsik untuk spektrum dengan S/N> 150 dihitung sebagai $\Delta T_{\rm eff}$= 51 K, $\Delta \log g$= 0,06, dan[Fe/H]= 0,08. Untuk seluruh spektrum

set data, termasuk spektrum S/N yang lebih rendah, kesalahan sebaran intrinsik

dua kali lebih besar dibandingkan ketika StarNet dilatih dengan parameter ASPCAP. Hal ini kemungkinan disebabkan oleh efek sistematis yang tidak diperhitungkan pada waktu pelatihan, misalnya efek instrumental atau kepunahan. Perluasan StarNet untuk memasukkan efek pemodelan sintetis yang tidak diperhitungkan direncanakan untuk pekerjaan di masa depan.

Kepunahan antar bintang, kepunahan atmosfer, dan tanda tangan instrumental tidak disimulasikan dalam spektrum sintetis. Efek-efek ini dapat bervariasi dari satu bintang ke bintang lainnya, umumnya memengaruhi area yang lebih biru pada

[1]) Spektrum ASSET hanya tersedia dengan normalisasi kontinum menggunakan metode ASPCAP, oleh karena itu kami menggunakan spektrum DR12 yang dinormalisasi ASPCAP untuk menguji implementasi StarNet ini. Skema normalisasi non-ASPCAP yang dijelaskan pada Bagian 4.1 hanya diterapkan ketika StarNet dilatih pada spektrum APOGEE DR13

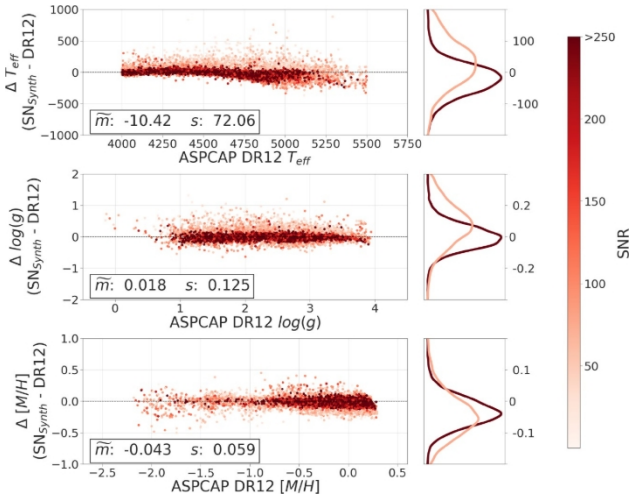

Gambar 10. Residual dari prediksi StarNet dan parameter ASPCAP untuk satu set pengujian 21.787 spektrum gabungan dari APOGEE. Perbandingan dilakukan dengan DR12 untuk konsistensi karena pengujian kami menggunakan grid sintetis ASSET (tidak digunakan untuk DR13). StarNet dilatih pada 224.000 spektrum sintetis yang diambil secara acak dari grid sintetis ASSET dengan melakukan interpolasi antara titik-titik grid. Proyeksi distribusi rata-rata ditampilkan di sebelah kanan (merah tua untuk spektrum pengamatan dengan S/N> 150, merah muda untuk S/N< 100). Nilai median (m˜) dan standar deviasi (s) dihitung di setiap panel, seperti pada Gambar 2.

spektrum sebagai fungsi yang bervariasi dengan lancar. Mengingat spektrum APOGEE mencakup panjang gelombang inframerah untuk sebagian besar objek terang di dekatnya (H> 12.5), efek kepunahan diharapkan tidak terlalu signifikan. Pada Bagian 4.7, sensitivitas model StarNet terhadap berbagai fitur dalam spektrum DR13 dibahas.

Menambahkan derau pada himpunan sintetis juga pada tahap pelatihan menurunkan StarNet untuk mempelajari fitur-fitur yang mempengaruhi estimasi parameter bintang, sambil mengabaikan fitur-fitur lemah yang tidak dapat dideteksi pada spektrum APOGEE yang bising. Dengan memvariasikan tingkat derau, ditemukan bahwa S/N> 20 diperlukan untuk mengurangi sebaran intrinsik residual sebelum kejenuhan. Menambahkan noise pada set pelatihan sintetis tidak hanya membantu mereproduksi pengaturan yang lebih realistis, tetapi juga memperhitungkan beberapa ketidakpastian dalam pemodelan fisik dan in-situ dan mengurangi overfitting. Karena kumpulan data APOGEE sebagian besar terdiri dari spektrum S/N yang tinggi, maka menambahkan model derau sederhana tampaknya cukup untuk memodelkan spektrum APOGEE. Akan tetapi, aplikasi potensial pada data non-APOGEE (atau data APOGEE dengan parameter bintang yang lebih sensitif) mungkin memerlukan model noise yang lebih teliti.

4.7 Derivatif parsial

Kita dapat memeriksa model yang telah dipelajari untuk menentukan bagian mana dari spektrum yang dibobot oleh NN ketika memprediksi parameter bintang. Kami melakukan ini dengan menghitung turunan parsial dari setiap output ($T_{\rm eff}$, log g, dan [Fe/H]) sehubungan dengan setiap nilai fluks input dari spektrum tertentu untuk mendapatkan Jacobian (seperti yang dijelaskan dalam Bagian 3.2).

Pada Gambar 11 dan 12 - untuk StarNet yang dilatih dengan spektrum APOGEE DR13 dan spektrum sintetik - kami menunjukkan rata-rata nilai absolut Jacobian dari 2000 bintang yang berada pada rentang tertentu dalam ruang parameter. Jacobian dari bintang-bintang yang miskin logam dibandingkan dengan Jacobian dari bintang-bintang yang kaya logam. Perbandingan juga dilakukan antara bintang-bintang panas dan dingin. Kami fokus pada sub-bagian dari chip hijau dari 15.950 hingga 16.180. Beberapa fitur

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

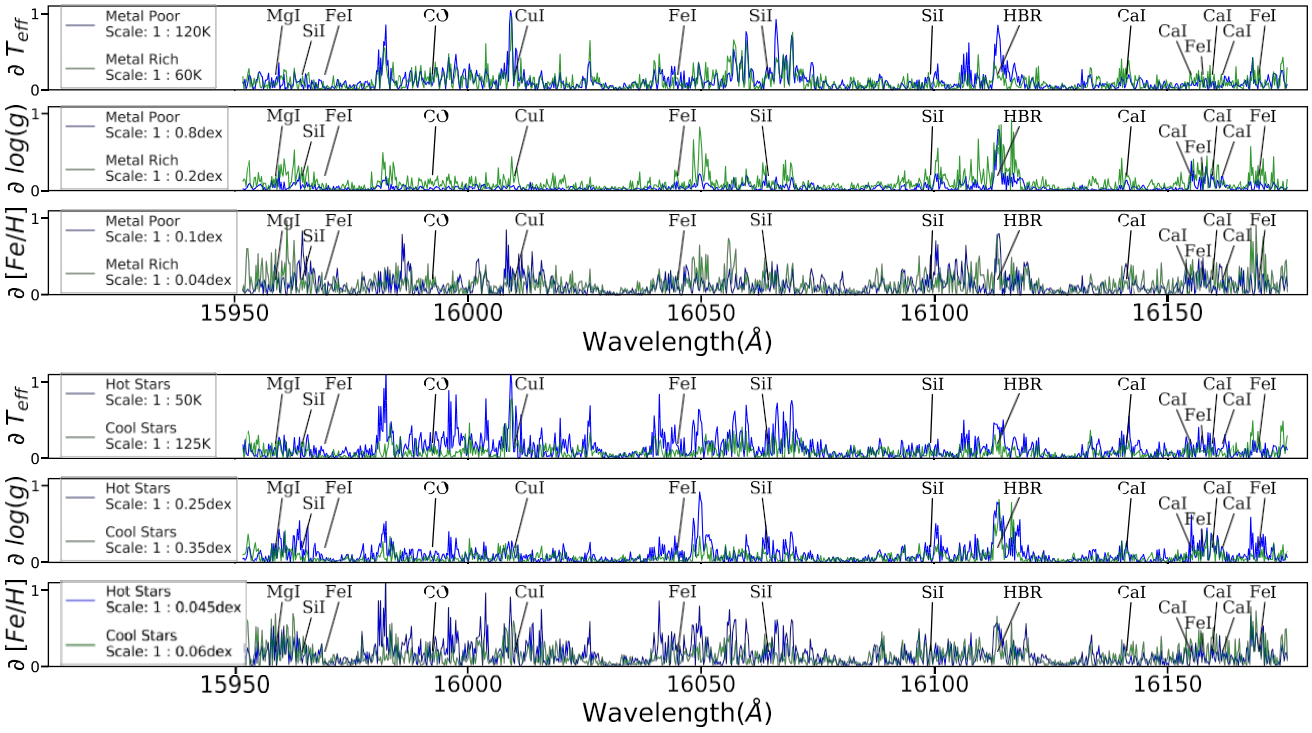

Gambar 11. Turunan parsial dari tiga parameter keluaran bintang dari model StarNet - yang dilatih pada spektrum APOGEE - sehubungan dengan panjang gelombang masukan untuk bagian chip hijau. Turunan parsial bintang-bintang dari berbagai rentang ruang parameter dibandingkan satu sama lain. Bintang-bintang dengan [Fe/H]> 0,0 dibandingkan dengan bintang-bintang dengan [Fe/H] < − 1,2 (atas). Demikian pula, bintang-bintang dengan $T_{(eff)}$ > 5000 K dibandingkan dengan bintang-bintang dengan $T_{(eff)}$ < 4300 K (bawah). Sebuah
Nilai absolut rata-rata Jacobian dihitung dari 2000 bintang di setiap rentang parameter. Perhatikan perbedaan skala saat membandingkan turunan parsial.

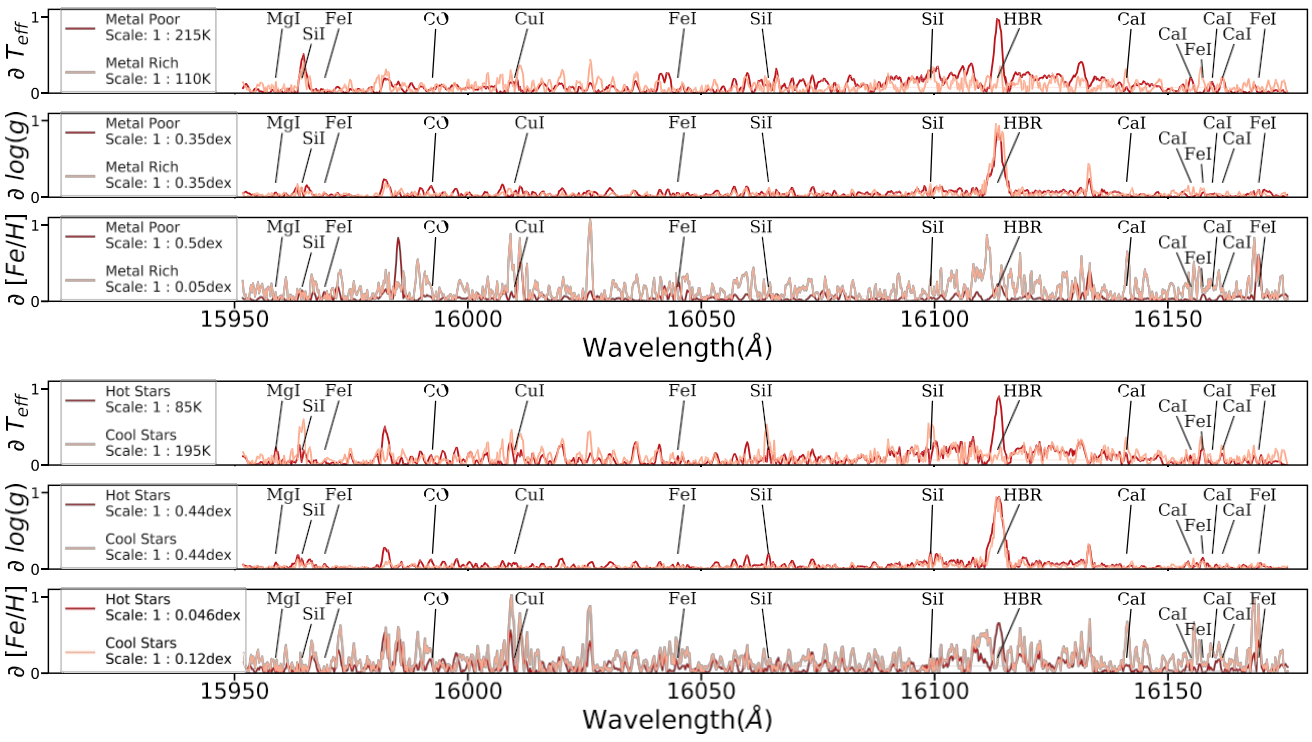

Gambar 12. Derivatif parsial dari tiga parameter keluaran bintang dari model StarNet - yang dilatih dengan data sintetis - sehubungan dengan masukan panjang gelombang untuk bagian chip hijau. Turunan parsial bintang-bintang dari berbagai rentang ruang parameter dibandingkan satu sama lain. Bintang-bintang dengan [Fe/H]> 0,0 dibandingkan dengan bintang-bintang dengan [Fe/H]< − 1,2 (atas). Demikian pula bintang-bintang dengan $T_{(eff)}$ > 5000 K dibandingkan dengan bintang-bintang dengan T_{eff}< 4300 K (bawah). Sebuah
Nilai absolut rata-rata Jacobian dihitung dari 2000 bintang di setiap rentang parameter. Perhatikan perbedaan skala saat membandingkan turunan parsial.

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

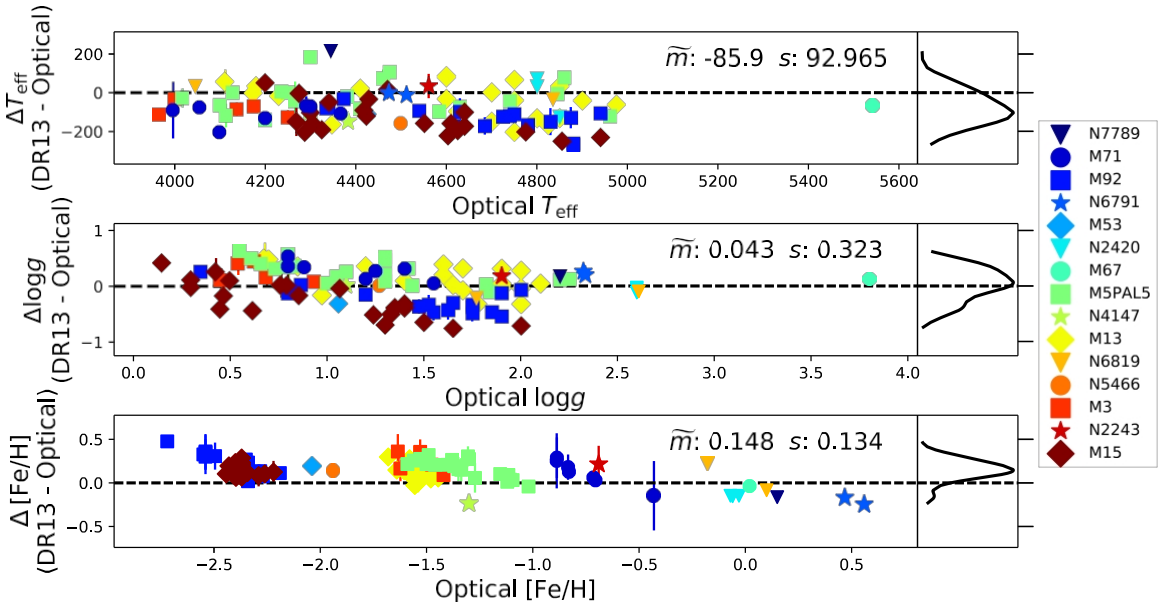

Gambar 13. Perbandingan parameter bintang ASPCAP DR13 untuk 102 bintang dalam gugus dengan parameter optik yang bersumber dari literatur. Ketika beberapa sumber literatur tersedia untuk bintang tertentu, rata-rata parameter yang dilaporkan ditampilkan dengan batang kesalahan yang ditentukan oleh standar deviasi data optik yang ditambahkan dalam kuadratur dengan kesalahan yang dihasilkan oleh StarNet. Lihat Tabel B1 untuk daftar referensi literatur. Nilai median (m˜) dan simpangan baku (s) dihitung pada setiap panel, seperti pada Gbr. 2.

dilabeli dari daftar jalur input APOGEE. Beberapa fitur penting termasuk:

(i) Garis-garis hidrogen (HBR): Garis-garis ini berperan penting tidak hanya dalam penentuan gravitasi tapi juga dalam penentuan temperatur pada bintang-bintang yang miskin logam.

(ii) Garis-garis logam atomik (misalnya FeI, CaI, dan CuI): Garis-garis ini memainkan peran penting dalam penentuan temperatur dan metalitas di seluruh rentang parameter bintang.

(iii) Garis-garis logam atom tertentu dalam kisi sintetis yang berperan dalam penentuan suhu, misalnya SiI muncul lebih banyak dan CaI muncul kurang signifikan.

(iv) Garis-garis tak dikenal atau lebih lemah yang tidak digunakan dalam fungsi jendela APOGEE, namun memainkan peran penting dalam penentuan semua parameter bintang dari spektrum yang diamati.

(v) Garis-garis yang tidak teridentifikasi atau lebih lemah hanya berperan penting dalam penentuan metalitas untuk bintang-bintang dingin dan bintang-bintang yang kaya akan logam.

Tak satu pun dari fitur-fitur ini dipilih sebelumnya atau diberi bobot secara eksternal sebelum JST dilatih. Kami juga membandingkan turunan parsial untuk himpunan bagian dari bintang-bintang dengan S/N< 60 versus S/N> 200, namun tidak menemukan perbedaan yang mencolok dalam kekuatan prediksi. Hasil yang sama juga terlihat pada daerah panjang gelombang lainnya di seluruh rentang spektrum APOGEE.

5 D PEMBAHASAN

5.1 Bintang patokan optik

Keakuratan parameter yang dikembalikan oleh StarNet dibatasi oleh kualitas data pelatihan. Ketika StarNet dilatih dengan parameter bintang AS- PCAP, ketidakpastian dalam pipa ASPCAP secara implisit disebarkan ke seluruh hasil. Salah satu pilihan untuk menguji ketepatan hasil APOGEE StarNet adalah membandingkannya dengan analisis optik. Parameter dan kelimpahan bintang untuk setiap individu bintang yang diperoleh melalui analisis optik dapat memiliki presisi yang lebih tinggi karena tersedianya spektograf optik beresolusi lebih tinggi, akses ke lebih banyak fitur spektral, dan keyakinan yang lebih tinggi pada model atmosfer bintang optik (lihat Sneden dkk. 2004; Gilmore dkk. 2012; Venn 2012; Aoki dkk. 2013; Yong dkk. 2013; Howes dkk. 2014; Roederer dkk. 2014; Domba dkk. 2015).

Untuk menyelidiki keakuratan prediksi StarNet dari hasil pelatihan spektrum sintetik, semua bintang dari pangkalan data APOGEE DR13 yang memiliki bendera 'Kalibrasi-Klaster' atau 'Bintang Standar' dipilih untuk membuat kelompok bintang patokan dengan parameter ASPCAP. Parameter yang ditentukan dari analisis spektral optik kemudian diperoleh untuk bintang-bintang ini melalui pencocokan langsung pengenal APOGEE / pengenal MASS (Skrutskie et al. 2006) dengan bintang-bintang dalam katalog Pastel 2016 (Soubiran et al. 2016), dan dilengkapi dengan data tambahan dari referensi dalam Me´sza´ros dkk. (2013) dan Holtzman dkk. (2015). Gambar 13 membandingkan parameter bintang ASPCAP DR13 dengan parameter yang ditentukan secara optik untuk 102 bintang benchmark (ditabulasikan pada Lampiran B, beserta referensinya).

Dengan melihat Gambar 13, terdapat offset kecil antara ASPCAP DR13 dan nilai optik untuk ketiga parameter bintang. Dengan membandingkan Gambar 13 dengan 3 - di mana StarNet dilatih pada spektrum yang diamati dan dibandingkan dengan ASPCAP - bias yang sama pada [Fe/H] rendah terlihat residu. Bias yang terlihat pada Gbr. 3 kemungkinan besar disebabkan oleh bias ukuran sampel pada set pelatihan StarNet, meskipun bias pada Gbr. 13 dapat disebabkan oleh cakupan yang tidak mencukupi pada kisi sintetis. Bias sistematik ini memerlukan sampel referensi yang lebih besar dari ruang parameter, serta kemungkinan perbaikan dalam cakupan spektrum teoritis.

Membandingkan sebaran residu antara prediksi DR13 ASPCAP dan StarNet (Gbr. 3) dengan sebaran pada prediksi analisis optik (Gbr. 13), kita melihat bahwa analisis optik memiliki sebaran yang lebih besar dengan faktor &2 pada T_{eff}, &4 pada log g, dan &4 pada [Fe/H]. Sebaran yang lebih besar menunjukkan bahwa penurunan ketidakpastian statistik yang disederhanakan sudah cukup hingga kita bisa mengkalibrasi parameter bintang untuk sekumpulan bintang acuan yang lebih homogen.

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

Parameter bintang yang terkalibrasi dengan baik akan membutuhkan model probabilistik yang lebih teliti dari pelatihan StarNet dan prediksi StarNet. Oleh karena itu, kami menganggap kesepakatan ini sangat baik dan tidak menyelidiki dispersi intrinsik ini lebih lanjut pada saat ini.

Perbandingan Gambar 10 dan 13 menunjukkan bahwa, ketika StarNet dilatih pada spektrum sintetis dan dibandingkan dengan DR12, adalah faktor~ 2 lebih rendah daripada residu antara DR13 dan optik analisis. Namun, karena input fisika yang berbeda, teknologi analisis Karena perbedaan karakteristik, resolusi spektral, dll. antara StarNet, APOGEE, dan analisis optik, kami tidak dapat secara langsung membandingkan ketepatan parameter bintang yang dihasilkan oleh StarNet dan analisis optik saat ini. Sebaliknya, tingkat sebaran yang sama pada residual mengindikasikan bahwa kesalahan sistematik yang ada pada StarNet sebanding dengan kesalahan sistematik yang diharapkan dari analisis optik. Hal ini mengindikasikan bahwa model StarNet cukup memadai untuk analisis survei tunggal dan dapat memberikan alat yang baru dan menarik untuk analisis yang efisien dari survei spektroskopi.

5.2 Katai M di DR13

Meskipun APOGEE terutama mengamati bintang-bintang raksasa dan sub-raksasa merah, DR13 juga mengamati spektrum bintang katai M yang sudah diketahui. Bintang-bintang ini disertai dengan Bendera Target khusus: 'APOGEE MDWARF'. Awalnya, kami belum mengeluarkan bintang-bintang ini dari kumpulan data dan menemukan perbedaan yang jelas antara hasil StarNet dan hasil dari ASPCAP DR13. Setelah diamati lebih dekat, kami menemukan 5900 bintang yang mirip dengan katai M yang sudah diketahui, tapi belum ditandai sebagai katai M. Bintang-bintang tersebut dikeluarkan dari kumpulan data kami, dengan menggunakan salah satu cara berikut:

(i) Parameter metalitas dari− 0.9 < (ASPCAP [Fe/H]) < 1.0, dan di mana (StarNet [Fe/H]− ASPCAP [Fe/H]) <− 0.4, atau

(ii) Parameter gravitasi dari (ASPCAP log g) >3.6, dan di mana (StarNet log g− ASPCAP log g) <− 0.3

Grid ASSET yang disertakan dalam rilis data APOGEE DR12 tidak menyertakan spektrum sintetik katai M. Oleh karena itu, StarNet tidak dapat dilatih pada bintang-bintang tersebut. Selain itu, StarNet tidak dapat dilatih pada spektrum yang diamati saat ini karena jumlah katai M yang ada di dalam set data APOGEE terlalu sedikit (<1000 yang ditandai). Metode kami untuk menandai katai M tidak kuat, misalnya, beberapa bintang RGB mungkin telah dihapus, sementara katai M lainnya tidak.

5.3 Pertimbangan NN

Salah satu keterbatasan dari NN dalam adalah perlunya set pelatihan yang besar yang mencakup ruang parameter yang luas. Distribusi parameter bintang dalam himpunan pelatihan untuk Star- Net (ketika dilatih pada spektrum yang diamati) ditunjukkan pada Gbr. 14. Dari plot-plot tersebut, terlihat bahwa spektrum bintang pada temperatur tinggi, metalitas rendah, dan gravitasi rendah lebih sedikit. Seperti yang terlihat pada Gambar 3 dan 7, memiliki lebih sedikit spektrum pelatihan pada bagian ruang parameter ini menghasilkan prediksi yang kurang akurat ketika menguji bintang-bintang di wilayah tersebut. StarNet juga ditantang ketika kombinasi parameter yang terbatas langka dalam set pelatihan. Sebagai contoh, ketika StarNet dilatih pada APOGEE Spektrum DR13, hanya ada sedikit sekali bintang dengan 4500 K≤ $T_{\rm eff}$≤ 5200 K, 1≤ log g≤ 2, dan [Fe/H] ≤− 1.6 dalam set referensi (lihat Gambar 4). Masalah ini dapat diatasi dengan menyesuaikan batasan yang ditetapkan pada set referensi StarNet, tetapi mungkin memerlukan biaya dalam hal akurasi.

Sementara pengamatan bintang dibatasi oleh waktu dan sumber daya, menghasilkan spektrum sintetis hanya dibatasi oleh sumber daya komputasi. Kemampuan untuk menghasilkan spektrum sintetis yang secara merata menjangkau ruang parametrik dapat meningkatkan kemampuan JST untuk memprediksi di wilayah

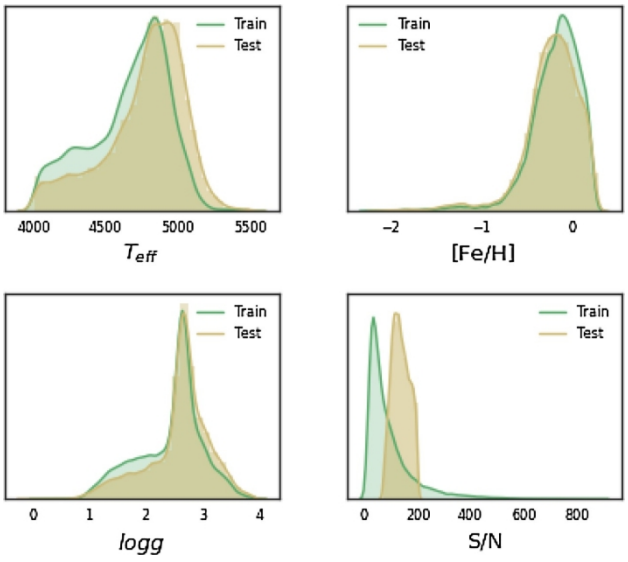

Gambar 14. Distribusi parameter dalam set pelatihan dan pengujian StarNet ketika StarNet dilatih dan diuji pada spektrum APOGEE DR13. StarNet mungkin tidak dapat menguji dengan baik pada bintang-bintang yang menempati ruang parameter yang kurang terisi oleh himpunan pelatihan.

yang mungkin dipengaruhi oleh bias sampel. Kami melihat hal ini sebagai salah satu kekuatan StarNet.

Di masa depan, kami membayangkan menggabungkan spektrum yang diamati dengan spektrum yang dihasilkan secara sintetis untuk meningkatkan ketepatan prediksi StarNet. Hal ini akan meningkatkan jumlah spektrum pelatihan pada seluruh rentang parameter, sekaligus mengurangi efek dari celah sintetis. Tentu saja, aplikasi NN ini tidak terbatas pada wilayah panjang gelombang APOGEE, tetapi dapat diperluas ke survei spektroskopi lainnya.

Akhirnya, beberapa skeptisisme muncul di sekitar pembelajaran mesin karena sejarahnya yang tidak dapat diakses dan kompleksitasnya; terkadang dianggap sebagai kotak hitam. Perkembangan baru telah meningkatkan kegunaan dan membuat pembelajaran mesin jauh lebih mudah diakses. Pelatihan dan pengujian semua model yang digunakan dalam makalah ini dilakukan dengan pustaka NN, KERAS (Chollet 2015), yang menyediakan antarmuka program aplikasi tingkat tinggi untuk paket perangkat lunak kecerdasan mesin TENSORFLOW (Abadi et al. 2015). Kami menyediakan kode untuk mereproduksi langkah-langkah pelatihan dan pengujian pada kumpulan data APOGEE DR13 dengan StarNet di https://github.com/astroai/starnet.

6 KESIMPULAN

Kami telah menyajikan model CNN yang mampu menentukan parameter bintang $T_{\rm eff}$, log g, dan [Fe/H] secara langsung dari spektrum. Pengembangan model ini, StarNet, mencakup pelatihan dan pengujian pada spektrum nyata (dari pangkalan data APOGEE) dan spektrum sintetis (dari grid APOGEE ASSET). Kami telah menerapkan prosedur optimasi untuk penyetelan hiper-parameter, memeriksa ketepatan prediksi parameter bintang saat mengembangkan arsitektur StarNet.

Dengan menerapkan model StarNet pada berbagai rilis data survei APOGEE, kami menunjukkan bahwa model ini mampu mengestimasi parameter bintang dari *spektrum sintetis.* Parameter-parameter ini dan ketidakpastiannya mirip dengan hasil ASPCAP. Kami juga membandingkan StarNet dengan metode *berbasis data* lainnya (seperti Cannon 2) dan menemukan hasil yang serupa ketika dilatih dengan set data pengamatan yang cukup besar.

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

Dalam aplikasi kami pada set data APOGEE, kami juga mengeksplorasi keterbatasan set pelatihan; ukuran sampel; rentang parameter bintang; dampak nilai fluks-nol pada spektrum nyata selama pelatihan dan selama pengujian; dan efek S/N spektrum pada akurasi prediksi StarNet. Hasil penelitian kami adalah
kuat pada rentang nilai S/N yang luas untuk spektrum APOGEE, termasuk S/N rendah∼ 15.

Di masa depan, pengujian kesalahan intrinsik dalam model NN harus Variasi dalam kisi-kisi spektral sintetis, misalnya variasi dalam model atmosfer yang diadopsi ketika menghasilkan spektrum sintetis, perubahan dalam metode normalisasi kontinum, serta eksplorasi daerah panjang gelombang yang berbeda. Kami sangat tertarik untuk menerapkan StarNet pada survei dan pengamatan spektroskopi optik.

AC TAHU PERNYATAAN

Kami berterima kasih kepada penelaah anonim atas komentar-komentarnya yang sangat membantu dalam menyempurnakan naskah ini. Makalah ini pertama kali dipresentasikan di l'Observatoire de la Coˆte d'Azur di Nice, Prancis, pada tanggal 1 Juni 2017 dan sekali lagi (sebagian) pada pertemuan Joint Institute for Nuclear Astrophysics Forging Connections di Lansing, Michigan, pada bulan Juni 2017.
28. Mike Irwin (Institute of As- tronomy, University of Cambridge) dan Dr. Jo Bovy (University of Toronto) atas komentar-komentar yang sangat membantu dalam penelitian ini, serta Dr. Vanessa Hill, Alejandra Recio-Blanco, dan Patrick de Laverny (Observatoire de la Coˆte d'Azur, Perancis) atas diskusi-diskusi menarik mengenai analisis spektral. SB dan TO berterima kasih kepada Dewan Riset Nasional Kanada Herzberg Astronomi dan Astrofisika atas pendanaan melalui program kerja sama mereka. KAV, KK, FJ, SB, TO, dan SM berterima kasih atas pendanaan sebagian untuk penelitian ini melalui penghargaan Program Pengalaman Penelitian dan Pelatihan Kolaboratif Dewan Riset Ilmu Pengetahuan dan Teknik Nasional di bidang *Teknologi Baru untuk Observatorium Kanada.*

REFERENSI

Abadi M. dkk., 2015, TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems, tersedia di: http://tensorflow.org/
Albareti F. D. dkk., 2017, ApJS, 233, 25
Allende-Prieto C. dkk., 2008, AJ, 136, 2070
Aoki W. dkk., 2013, AJ, 145, 13
Bailer-Jones CA, 2000, A&A, 357, 197
Bailer-Jones CA, Irwin M., Gilmore G., von Hippel T., 1997, MNRAS, 292, 157
Bergstra JS, Bardenet R., Bengio Y., Ke'gl B., 2011, dalam Shawe-Taylor J., Zemel , Bartlett PL, Pereira F., Weinberger KQ, eds, Advances in Neural Information Processing Systems 24. Curran Associates, Inc, New York, hal. 2546
Bessell M., 1983, PASP, 95, 94
Bragaglia A. dkk., 2001, AJ, 121, 327
Brown JA, Wallerstein G., Oke J., 1991, AJ, 101, 1693 Carretta E.,
Gratton R., 1997, A&AS, 121, 95
Carretta E., Bragaglia A., Gratton R., 2007, A&A, 473, 129
Carretta E. dkk., 2009, A&A, 505, 117
Casey ARarXiv: 1603.03040, Hogg DW, Ness M., Rix H.-W., Ho AQ, Gilmore G., 2016, ApJ, pracetak ()
Cavallo RM, Nagar NM, 2000, AJ, 120, 1364
Chen S., Billings S., Grant P., 1990, Int. J. Kontrol, 51, 1191
Chollet F., 2015, Keras, tersedia di: https://github.com/fchollet/keras
Cohen J., 1978, ApJ, 223, 487
Cohen J., 1979, ApJ, 231, 751
Cohen J., 1980, ApJ, 241, 981
Cunha K. dkk., 2015, ApJ, 798, L41
Dotter A., Chaboyer B., Jevremovic D., Kostov V., Baron E., Ferguson J. J. W., 2008, ApJS, 178, 89
Garcia-Pe´rez A. E. dkk., 2016, AJ, 151, 144 Gilmore
G. dkk., 2012, Messenger, 147, 25
Goodfellow I., Bengio Y., Courville A., 2016, Deep Learning. MIT Press, Cambridge, MA
Gratton R., 1982, ApJ, 257, 640
Gratton RG, Quarta ML, Ortolani S., 1986, A&A, 169, 208 Gratton RG,
Contarini G., 1994, A&A, 283, 911
Gratton R., Bragaglia A., Carretta E., Tosi M., 2006, ApJ, 642, 462 Gurney K.,
1997, Pengantar Jaringan Syaraf Tiruan. CRC Press, London He K., Zhang X.,
Ren S., Sun J., 2015, CoRR, abs/1502.01852
Holtzman JA dkk., 2015, AJ, 150, 148
Howes LM dkk., 2014, MNRAS, 445, 4241
Jahandar F. dkk., 2017, MNRAS, 470, 4782
Kingma D., Ba J., 2014, pracetak (arXiv: 1412.6980)
Koesterke L., Prieto CA, Lambert DL, 2008, ApJ, 680, 764 Kraft R. P.,
Sneden C., Langer G., Prosser CF, 1992, AJ, 104, 645
Kraft R. P., Sneden C., Langer G., Shetrone MD, 1993, AJ, 106, 1490 Kraft R.
P., Sneden C., Smith GH, Shetrone MD, Langer G., Pilachowski C. C., 1997, AJ, 113, 279
Kraft . P., Peterson RC, Guhathakurta P., Sneden C., Fulbright JP, Langer GE, 1999, ApJ, 518, L53
Lai DK, Smith GH, Bolte M., Johnson JA, Lucatello S., Kraft RP, Sneden C., 2011, AJ, 141, 62
Lamb M., Venn K., Shetrone M., Sakari C., Pritzl B., 2015, MNRAS, 448, 42
Lee Y. dkk., 2008, AJ, 136, 2022
Lee Y. dkk., 2011, AJ, 141, 90
Leep EM, Wallerstein G., Oke J., 1987, AJ, 93, 338 Lehnert
M., Bell R., Cohen J., 1991, ApJ, 367, 514
Li X.-R., Pan R.-Y., Duan F.-Q., 2017, Research in A&A, 17, 036 Luck
R., Bond H., 1981, ApJ, 244, 919
Maaten L. v. d., Hinton G., 2008, J. Mach. Learn. Res. 9, 2579
Majewski S. R. dkk., 2017, AJ, 154, 94
Manteiga M., Ordo´n˜ez D., Dafonte C., Arcay B., 2010, PASP, 122, 608
Me´sza´ros S. dkk., 2012, AJ, 144, 120
Me´sza´ros S. dkk., 2013, AJ, 146, 133
Me´sza´ros S. dkk., 2015, AJ, 149, 153
Minniti D., Olszewski , Rieke M., 1993, ApJ, 410, L79
Molenda-Z˙akowicz J. dkk., 2013, MNRAS, stt1095
Ness M., Hogg DW, Rix H.-W., Ho , Zasowski G., 2015, ApJ, 808, 16
Nidever DL dkk., 2015, AJ, 150, 173
Pancino E., Carrera R., Rossetti E., Gallart C., 2010, A&A, 511, A56 Pancino E.
dkk., 2017, A&A, 598, 5
Peterson RC, 1980, ApJ, 237, L87
Pilachowski A., 1985, PASP, 97, 801
Pilachowski C., Leep E., Wallerstein G., 1980, ApJ, 236, 508
Pilachowski C., Sneden C., Wallerstein G., 1983, ApJS, 52, 241
Randich S., Sestito P., Primas F., Pallavicini R., Pasquini L., 2006, A&A, 450, 557
Recio-Blanco A. dkk., 2016, A&A, 589, 22
Recio-Blanco A. dkk., 2017, A&A, 602, 6
Roederer UI, Sneden C., 2011, AJ, 142, 22
Roederer UI, Preston GW, Thompson IB, Shectman SA, Sneden C., Burley GS, Kelson DD, 2014, AJ, 147, 136
Shetrone MD, Bolte M., Stetson PB, 1998, AJ, 115, 1888 Singh HP,
Gulati , Gupta R., 1998, MNRAS, 295, 312
Skrutskie MF dkk., 2006, AJ, 131, 1163 Smiljanic R.
dkk., 2014, A&A, 570, A122
Sneden C., Kraft R. P., Prosser C. F., Langer G., 1991, AJ, 102, 2001 Sneden
C., Kraft R. P., Prosser C. F., Langer G., 1992, AJ, 104, 2121 Sneden C., Kraft
R. P., Langer G., Prosser C. F., Shetrone MD, 1994, AJ, 107, 1773
Sneden C., Kraft RP, Shetrone MD, Smith GH, Langer G, Prosser CF, 1997, AJ, 114, 1964
Sneden C., Pilachowski C. A., Kraft RP, 2000, AJ, 120, 1351
Sneden C., Kraft R. P., Guhathakurta P., Peterson RC, Fulbright J. P., 2004, AJ, 127, 2162
Sobeck JS dkk., 2011, AJ, 141, 175

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

Soubiran C., Le Campion J.-F., Brouillet N., Chemin L., 2016, A&A, 591, A118
Venn KA dkk., 2012, ApJ, 715, 25
Von Hippel T., Storrie-Lombardi L., Storrie-Lombardi M., Irwin M., 1994, MNRAS, 269, 97
Wang K., Guo P., Luo A.-L., 2017, MNRAS, 465, 4311 Yanny B. dkk., 2009, AJ, 137, 4377
Yong D. dkk., 2013, ApJ, 762, 27

LAMPIRAN A: THE STARNET CNN

Dalam makalah ini, kami melakukan pendekatan untuk memprediksi parameter bintang dari spektrum dengan pembelajaran terawasi. Dari kumpulan data yang terdiri dari
spektrum bintang individu dan parameter fisis yang terkait, kami melakukan pendekatan fungsi untuk mempelajari pemetaan di antara keduanya. Untuk spektrum serupa lainnya, kami kemudian mengasumsikan model yang dilatih mampu
memprediksi parameter bintang.

Fungsi pemetaan kami diparameterisasi dan diatur sebagai NN. NN terdiri dari kumpulan neuron buatan atau node yang disusun dalam beberapa lapisan: *lapisan input* (dalam kasus kami, spektrum input), sejumlah *lapisan tersembunyi*, dan *lapisan output* (dalam kasus kami, parameter bintang). Setiap node diparameterkan sebagai fungsi linear dari bobot, $\boldsymbol{w}$, yang diterapkan pada input, $\boldsymbol{x}$, dengan nilai bias tambahan, b. Sebuah node kemudian diaktifkan oleh fungsi non-linear, g, yang memberikan output dari sebuah node yang akan dituliskan sebagai

$$h(\boldsymbol{x}) = g(\boldsymbol{w}^T \boldsymbol{x} + b).$$

Fungsi aktivasi yang umum termasuk fungsi sigmoid dan ReLU:

$$g(z) = \max(0, z),$$

yang memungkinkan jaringan beradaptasi dengan masalah non-linier (Chen, Billings & Grant 1990). Fungsi ReLU digunakan dalam implementasi untuk semua lapisan StarNet kecuali untuk lapisan output terakhir.

Dalam arsitektur NN berurutan tradisional, setiap node terhubung ke setiap node dari lapisan sebelumnya serta setiap node di lapisan berikutnya, yang kemudian disebut sebagai lapisan *yang terhubung sepenuhnya.*
ers. Pada lapisan tersembunyi, l, output, $\boldsymbol{h}^{(l)}$, adalah sebuah fungsi bernilai vektor dari lapisan sebelumnya, $\boldsymbol{h}^{(l-1)}$, dan diberikan oleh

$$\boldsymbol{h}^{(l)} = \boldsymbol{g}(\boldsymbol{W}^{(l)} \boldsymbol{h}^{(l-1)} + \boldsymbol{b}^{(l)}).$$

Lapisan pertama hanyalah input $\boldsymbol{h}^{(0)}(\boldsymbol{x}) = \boldsymbol{x}$; dalam kasus kami, spektrum.

Dua lapisan StarNet berikutnya adalah *lapisan konvolusi*, yang lebih disesuaikan dengan input dimensi yang lebih tinggi dengan memanfaatkan konektivitas lokal di lapisan sebelumnya. Pada lapisan konvolusi, bobot diterapkan sebagai filter. Filter meluncur melintasi lapisan sebelumnya dengan mengambil hasil kali titik antara bobot filter dan bagian input. Untuk filter yang diberikan yang mencakup bagian, s, operasi ini dapat diringkas sebagai

$$\boldsymbol{h}_s^{(l)} = \boldsymbol{g}(\boldsymbol{w}_s^{(l)} \otimes \boldsymbol{h}^{(l-1)} + \boldsymbol{b}_s).$$

Filter-filter ini memungkinkan ekstraksi fitur-fitur dalam input dan mempelajari fitur-fitur mana yang akan diekstrak melalui pelatihan. Setelah lapisan konvolusi di StarNet, kami menggunakan lapisan max pooling. Lapisan max pooling adalah teknik downsampling non-linear yang biasanya digunakan dalam CNN untuk mengurangi jumlah parameter bebas dan mengekstrak fitur terkuat dari lapisan convolutional. Dalam lapisan max pooling, sebuah jendela bergerak di sepanjang peta fitur yang dihasilkan oleh masing-masing filter pada lapisan convolutional sebelumnya - dalam langkah yang panjangnya sama dengan panjang jendela - mengekstraksi nilai maksimum dari setiap sub-wilayah. Kumpulan nilai maksimum ini kemudian diteruskan ke lapisan berikut. Dua lapisan berikutnya dalam StarNet adalah lapisan yang sepenuhnya terhubung.

Kombinasi dari semua lapisan tersebut memungkinkan pembentukan kombinasi non-linear dari vektor input, $\boldsymbol{x}$, untuk menghasilkan prediksi vektor output, $f(\boldsymbol{x}; \boldsymbol{w}, b)$. Untuk setiap sampel pelatihan spektrum, $\boldsymbol{x}_t$, dan parameter bintang yang diketahui, $\boldsymbol{y}_t$, bobot dan bias model NN diestimasi dengan meminimalkan *risiko empiris* yang menghitung *kerugian* antara prediksi dan target untuk sekumpulan T sampel pelatihan, yang sering kali dilengkapi dengan fungsi pengatur. Kami akhirnya mengadopsi fungsi kerugian MSE tanpa regularisasi untuk StarNet, sehingga risiko empiris StarNet dapat diminimalkan:

$$\arg\min_{\boldsymbol{w}, b} \frac{1}{T} \sum_{t=1}^{T} \left[\boldsymbol{y}_t - f(\boldsymbol{x}_t; \boldsymbol{w}, \boldsymbol{b}) \right]^2 .$$

Minimisasi dilakukan dengan algoritma stochastic gradient descent (SGD). Algoritma SGD memerlukan perhitungan gradien fungsi kerugian sehubungan dengan bobot dan membuat penyesuaian terhadap bobot tersebut secara berulang hingga mencapai minimum. Dalam kasus kami, pengoptimalan dilakukan dengan menggunakan ADAM (Kingma & Ba 2014), sebuah varian SGD yang menggunakan estimasi adaptif dari momen gradien untuk menyesuaikan tingkat pembelajaran. Pada awalnya, bobot model ditetapkan secara acak dan oleh karena itu prediksinya akan sangat buruk. Komputasi gradien dioperasikan secara mundur melalui setiap lapisan berurutan, sebuah proses yang disebut sebagai *propagasi balik*, dan merupakan bagian pelatihan yang mahal secara komputasi.

Dalam kasus StarNet, satu set validasi silang digunakan untuk menguji model setelah setiap iterasi untuk mengevaluasi apakah model telah membaik atau tidak; jika perbaikan tidak dilakukan setelah sejumlah iterasi, pelatihan dihentikan. Jumlah minimum ini dapat berbeda tergantung pada kompleksitas arsitektur model serta berbagai hiper-parameter (dibahas pada Bagian 4.3). Setelah setiap iterasi, set validasi silang dikirim melalui propagasi forwad tunggal, di mana output diprediksi dan dibandingkan dengan nilai target. Set ini tidak digunakan untuk pelatihan, tetapi hanya untuk memastikan bahwa model tidak terlalu pas dengan set pelatihan. Over-fitting terjadi ketika model mempelajari fungsi yang mungkin dapat menghitung output untuk set pelatihan dengan sangat baik, tetapi tidak dapat menggeneralisasi fungsi tersebut untuk diterapkan pada set pengujian yang tidak termasuk dalam pelatihan. Set validasi silang digunakan sebagai jenis jalan tengah antara set pelatihan dan set pengujian, dan memastikan bahwa overfitting tidak terjadi. Jika prediksi validasi silang tidak membaik setelah beberapa kali iterasi, pelatihan akan dihentikan. Menggunakan set validasi silang untuk menghindari overfitting dan menyetel parameter hiper adalah praktik umum dalam aplikasi pembelajaran mesin (Gurney 1997).

Setelah jumlah minimum tercapai, sebuah set uji terpisah - yang tidak termasuk dalam pelatihan atau validasi silang - dipilih untuk memastikan bahwa model bekerja dengan baik pada data baru. Untuk StarNet, set pengujian ini terdiri dari spektrum bintang dengan parameter bintang yang sudah diketahui yang digunakan untuk membandingkan dengan prediksi StarNet. Untuk penjelasan lebih mendalam mengenai deep NN, kami merujuk pembaca ke Goodfellow, Bengio & Courville (2016).

LAMPIRAN B: BINTANG-BINTANG PATOKAN OPTIK DALAM GUGUS

Dalam lampiran ini, kami membuat tabulasi (lihat Tabel B1) paramater bintang untuk bintang-bintang dalam gugus bola yang memiliki hasil APOGEE DR13 (berdasarkan analisis spektral IR) dan hasil literatur (berdasarkan analisis spektral optik resolusi tinggi). Sistematika kami

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

Tabel B1. Parameter bintang untuk bintang-bintang dalam gugus bola yang memiliki hasil APOGEE DR13 dan yang berdasarkan spektroskopi optik resolusi tinggi dalam literatur.

ID 2MASS	Cluster	APOGEE PERS Bendera	Parameter ASPCAP DR13			Parameter Optik			StarNetASPCAP			StarNetSynth			Referensi
			Teff (K)	log *g* (dex)	[Fe/H] (dex)	Teff (K)	log *g* (dex)	[Fe/H] (dex)	Teff (K)	log *g* (dex)	[Fe/H] (dex)	Teff (K)	log *g* (dex)	[Fe/H] (dex)	
Kesalahan Perwakilan			92	0.11	0.05	86	0.24	0.17	47	0.14	0.07	-	-	-	-
2M16412709+ 3628002	M13	-	4184	0.81	- 1.54	4348	0.98	- 1.54	4201	0.96	- 1.48	4405	0.99	- 1.61	h, ac, af, al
2M16413053+ 3629434	M13	-	4431	1.55	- 1.39	4410	1.2	- 1.44	4434	1.49	- 1.34	4429	1.47	- 1.42	ac, af
2M16413072+ 3630075	M13	Tinggi	4816	2.21	- 1.29	4750	1.9	- 1.5	4809	2.2	- 1.27	4742	1.9	- 1.36	k
2M16413082+ 3630130	M13	-	4658	1.45	- 1.58	4825	1.77	- 1.55	4665	1.74	- 1.56	4869	1.98	- 1.6	k, ag
2M16413476+ 3627596	M13	-	4213	1.2	- 1.33	4230	0.85	- 1.44	4205	1.14	- 1.3	4249	1.02	- 1.34	ad, af
2M16413482+ 3627197	M13	Tinggi	4171	1.17	- 1.34	4173	0.7	- 1.49	4157	1.12	- 1.3	4220	1.0	- 1.37	j, ad, af
2M16413684+ 3629289	M13	-	4547	1.68	- 1.43	4750	2.0	- 1.48	4582	1.89	- 1.5	4869	2.25	- 1.53	ag
2M16413707+ 3630378	M13	-	4550	1.62	- 1.48	4700	1.7	- 1.58	4597	1.87	- 1.49	4829	2.16	- 1.51	ag
2M16413870+ 3625380	M13	Tinggi	4168	1.17	- 1.31	4111	0.67	- 1.56	4134	1.09	- 1.29	4205	0.95	- 1.33	f, j, ac, ad, af, al
2M16413945+ 3632029	M13	-	4883	2.14	- 1.41	4850	2.1	- 1.56	4839	2.21	- 1.44	4970	2.47	- 1.45	ag
2M16414398+ 3622338	M13	Tinggi	4568	1.49	- 1.47	4600	1.4	- 1.55	4638	1.62	- 1.45	4712	1.63	- 1.47	k
2M16414478+ 3623273	M13	Tinggi	4529	1.67	- 1.47	4625	1.65	- 1.6	4522	1.57	- 1.49	4657	1.58	- 1.59	k, ag
2M16414528+ 3631068	M13	-	4679	1.8	- 1.41	4600	1.6	- 1.57	4742	2.0	- 1.34	4701	2.07	- 1.35	k, ag
2M16414558+ 3630328	M13	-	4711	1.86	- 1.43	4750	1.9	- 1.57	4781	2.19	- 1.35	4733	2.18	- 1.37	k
2M16414744+ 3628284	M13	-	4214	1.21	- 1.34	4180	0.8	- 1.46	4203	1.14	- 1.32	4261	1.14	- 1.34	ad, af
2M16414932+ 3625264	M13	Tinggi	4686	1.99	- 1.3	4600	1.6	- 1.58	4736	2.05	- 1.3	4741	1.92	- 1.27	k
2M16415037+ 3623417	M13	Tinggi	4702	1.9	- 1.4	4700	1.9	- 1.54	4771	1.94	- 1.35	4697	1.76	- 1.37	ag
2M16415160+ 3629363	M13	Tinggi	4914	2.02	- 1.38	4975	1.7	- 1.68	4782	1.95	- 1.51	4923	1.62	- 1.61	ag
2M16415239+ 3628395	M13	Tinggi	4668	1.96	- 1.39	4800	2.0	- 1.52	4631	1.85	- 1.52	4858	2.04	- 1.46	k
2M16415842+ 3628312	M13	Tinggi	4860	2.28	- 1.32	4900	2.0	- 1.53	4754	2.18	- 1.36	4901	2.05	- 1.48	k
2M16415862+ 3627465	M13	Tinggi	4719	1.94	- 1.49	4850	1.9	- 1.64	4618	1.89	- 1.43	5002	2.35	- 1.52	ag
2M13131736+ 1814463	M53	-	4314	0.74	- 1.84	4425	1.06	- 2.04	4414	1.04	- 1.79	4620	1.19	- 1.9	ah
2M07380627+ 2136542	N2420	-	4725	2.55	- 0.22	4850	2.6	- 0.07	4725	2.56	- 0.22	4696	2.57	- 0.22	am
2M07381549+ 2138015	N2420	-	4872	2.57	- 0.21	4800	2.6	- 0.06	4890	2.57	- 0.21	4855	2.71	- 0.18	am
2M07382696+ 2138244	N2420	-	4832	2.48	- 0.18	4800	2.6	- 0.03	4825	2.48	- 0.17	4824	2.65	- 0.16	am
2M12100405+ 1832532	N4147	Tinggi	4235	1.12	- 1.53	4383	1.1	- 1.3	4270	0.92	- 1.73	4458	0.79	- 1.86	ak
2M13414576+ 2824597	M3	-	4051	0.84	- 1.46	4137	0.69	- 1.62	4057	0.89	- 1.46	4277	0.76	- 1.52	j, r, x, y, ac, af, al
2M13421204+ 2826265	M3	-	3968	0.95	- 1.27	4000	0.54	- 1.64	3975	0.87	- 1.27	4172	0.55	- 1.42	r, x, y, ac, af, al
2M13421679+ 2823479	M3	-	4123	1.01	- 1.33	4250	0.93	- 1.42	4119	0.95	- 1.32	4260	0.97	- 1.4	j, ac, af
2M13423922+ 2827574	M3	Rendah	4104	1.06	- 1.27	4175	0.63	- 1.48	4110	1.03	- 1.3	4263	0.94	- 1.35	x, z
2M13424150+ 2819081	M3	-	3853	0.55	- 1.17	3966	0.45	- 1.53	3910	0.98	- 1.12	4110	0.51	- 1.27	r, x, y, ac, af
2M14052071+ 2829419	N5466	Tinggi	4341	1.28	- 1.8	4499	1.27	- 1.94	4472	1.38	- 1.67	4846	1.76	- 1.87	ah
2M08514401+ 1146245	M67	Tinggi	5476	3.93	- 0.02	5541	3.8	0.02	5363	3.62	- 0.1	5242	3.7	- 0.13	i
2M15174702 0204519+	M5PAL5	-	4361	1.22	- 1.25	4381	1.05	- 1.53	4362	1.27	- 1.25	4528	1.47	- 1.28	u
2M15180831+ 0158530	M5PAL5	-	4840	1.73	- 1.37	4961	1.84	- 1.59	4861	1.9	- 1.39	5164	2.36	- 1.25	u
2M15180987+ 0210088	M5PAL5	Rendah	4557	1.45	- 1.3	4630	1.44	- 1.56	4558	1.53	- 1.32	4751	1.77	- 1.32	u
2M15181075+ 0212356	M5PAL5	Rendah	4698	1.85	- 1.18	4740	1.82	- 1.37	4710	1.99	- 1.13	4843	2.43	- 1.13	u
2M15181867 0204327+	M5PAL5	Rendah	3995	1.04	- 1.05	4113	0.73	- 1.15	3996	1.09	- 1.06	4184	0.69	- 1.19	l, af, ak
2M15182262+ 0200305	M5PAL5	-	4035	1.05	- 1.03	4100	0.66	- 1.3	4034	1.11	- 1.02	4203	0.94	- 1.12	u
2M15182283 0203097+	M5PAL5	-	4251	1.35	- 1.11	4250	1.1	- 1.12	4234	1.3	- 1.11	4352	1.43	- 1.09	l, af
2M15182345+ 0159572	M5PAL5	-	4483	1.76	- 1.02	4300	1.3	- 1.11	4459	1.69	- 1.01	4381	1.61	- 1.05	l, af
2M15182591 0205076+	M5PAL5	-	4198	1.37	- 1.06	4300	0.8	- 1.02	4175	1.23	- 1.07	4283	1.31	- 1.09	l, af
2M15183223 0201341+	M5PAL5	-	4060	1.05	- 1.06	4200	1.0	- 1.09	4053	1.13	- 1.06	4236	0.98	- 1.13	l, af
2M15183531 0207400+	M5PAL5	-	4327	1.51	- 1.19	4409	1.3	- 1.35	4340	1.45	- 1.19	4487	1.7	- 1.21	af, aj, ak
2M15183738 0206079+	M5PAL5	Rendah	4241	1.1	- 1.17	4236	0.61	- 1.49	4240	1.08	- 1.2	4332	1.09	- 1.19	u
2M15183765 0201212+	M5PAL5	-	4839	2.31	- 1.25	4845	2.2	- 1.46	4835	2.28	- 1.27	5132	2.7	- 1.22	u
2M15184132 0205014+	M5PAL5	-	4534	1.73	- 1.19	4460	1.42	- 1.34	4534	1.82	- 1.2	4589	1.96	- 1.16	u, af, aj
2M15184164 0203533+	M5PAL5	-	4128	1.19	- 1.07	4128	0.83	- 1.11	4103	1.09	- 1.07	4216	1.05	- 1.13	l, af, ak
2M15184346 0203074+	M5PAL5	-	4581	1.82	- 1.12	4475	1.3	- 1.38	4615	1.91	- 1.13	4540	1.9	- 1.1	u
2M15184374 0208171+	M5PAL5	Rendah	4938	2.37	- 1.19	4860	2.25	- 1.4	4865	2.29	- 1.18	5036	3.15	- 1.04	u
2M15184495 0202034+	M5PAL5	-	3990	1.17	- 1.0	4017	0.55	- 1.3	3981	1.01	- 1.02	4123	0.79	- 1.14	ak, al
2M15184540 0204302+	M5PAL5	-	4223	1.14	- 1.21	4266	0.8	- 1.27	4222	1.11	- 1.25	4363	1.09	- 1.25	l, u, af, ak, al
2M15185515+ 0214337	M5PAL5	-	4487	1.38	- 1.28	4584	1.3	- 1.5	4489	1.51	- 1.31	4669	1.75	- 1.29	u
2M17163427+ 4307363	M92	-	4638	1.19	- 2.24	4750	1.63	- 2.54	4791	1.78	- 1.86	4771	1.41	- 2.14	ab, ae
2M17165185+ 4308031	M92	-	4620	1.41	- 2.24	4740	1.75	- 2.72	4761	1.73	- 1.81	4765	1.98	- 2.03	ae
2M17165557+ 4309277	M92	-	4264	0.6	- 2.19	4340	0.35	- 2.27	4382	1.05	- 1.93	4454	0.74	- 2.3	x
2M17165738+ 4307236	M92	-	4254	0.67	- 2.15	4335	0.8	- 2.28	4352	1.03	- 1.95	4430	0.81	- 2.28	n, x, ab, af
2M17165772+ 4314115	M92	-	4443	1.11	- 2.21	4615	1.48	- 2.34	4515	1.34	- 1.89	4612	1.41	- 2.24	ab, ae
2M17165883+ 4315116	M92	-	4513	1.08	- 2.2	4685	1.55	- 2.34	4746	1.65	- 1.78	4654	1.27	- 1.99	ab, ae
2M17165956+ 4306456	M92	-	4618	1.35	- 2.32	4880	1.9	- 2.34	4723	1.63	- 1.88	4979	1.99	- 2.31	ab
2M17165967+ 4301058	M92	Tinggi	4746	1.77	- 2.11	4875	1.9	- 2.34	4803	1.87	- 1.73	4904	2.32	- 1.92	ab, ae
2M17170033+ 4311478	M92	-	4680	1.26	- 2.19	4830	1.75	- 2.54	4677	1.54	- 1.86	4817	1.77	- 2.0	ab, ae
2M17170043+ 4305117	M92	-	4601	1.35	- 2.19	4725	1.65	- 2.5	4727	1.77	- 1.84	4626	1.56	- 2.08	ab, ae
2M17170081+ 4310251	M92	-	4531	1.19	- 2.18	4630	1.52	- 2.54	4655	1.6	- 1.88	4679	1.52	- 2.08	ab, ae
2M17170647+ 4306029	M92	-	4613	1.37	- 2.22	4780	1.75	- 2.55	4679	1.61	- 1.88	4812	1.88	- 2.06	ae
2M17170731+ 4309308	M92	-	4447	1.05	- 2.16	4540	1.2	- 2.34	4532	1.33	- 1.9	4542	1.16	- 2.11	ab
2M17171221+ 4302209	M92	Tinggi	4833	1.93	- 2.08	4940	2.0	- 2.35	4768	1.83	- 1.73	4920	2.28	- 1.9	ae
2M17171307+ 4309483	M92	-	4341	0.88	- 2.08	4373	0.87	- 2.19	4470	1.28	- 1.88	4385	0.91	- 2.0	n, ab, af
2M21290843+ 1209118	M15	-	4467	1.08	- 2.14	4640	1.4	- 2.37	4595	1.35	- 1.91	4507	1.09	- 2.0	ab
2M21294465+ 1207307	M15	-	4451	0.96	- 2.19	4610	1.35	- 2.37	4570	1.26	- 1.88	4600	1.34	- 2.08	ab
2M21294979+ 1211058	M15	Rendah	4303	0.69	- 2.16	4423	0.86	- 2.26	4475	1.15	- 1.94	4420	0.75	- 2.12	e, n, n, o, o, q, ab, af, af
2M21295311+ 1212310	M15	-	4382	0.83	- 2.22	4604	1.33	- 2.34	4468	1.25	- 1.98	4596	1.11	- 2.21	d, ab
2M21295492+ 1213225	M15	Rendah	4145	0.29	- 2.27	4305	0.47	- 2.39	4303	0.82	- 1.95	4405	0.66	- 2.36	d, m, o, o, ab
2M21295560+ 1212422	M15	-	4395	0.8	- 2.18	4429	0.79	- 2.38	4498	1.13	- 1.9	4542	1.12	- 2.03	d, o, o

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024

Tabel B1 - *lanjutan*

ID 2MASS	Cluster	APOGEE PERS Bendera	ASPCAP DR13 Parameter [Fe/H] T_{eff} (K)	log g (dex)	[Fe/H] (dex)	Optical Parameters T_{eff} (K)	log g (dex)	[Fe/H] (dex)	StarNetASPCAP T_{eff} (K)	g (dex)	[Fe/H] (dex)	Log StarNetSyph T_{eff} (K)	g (dex)	[Fe/H] (dex)	Referensi
2M21295562+ 1210455	M15	-	4250	0.56	- 2.16	4200	0.15	- 2.37	4387	1.04	- 1.92	4376	0.63	- 2.1	o, o, ab
2M21295618+ 1212337	M15	-	4327	0.77	- 2.21	4418	0.76	- 2.29	4489	1.17	- 1.92	4456	0.9	- 2.09	n, n, o, o, af
2M21295666+ 1209463	M15	Tinggi	4120	0.28	- 2.34	4269	0.3	- 2.44	4274	0.81	- 1.94	4381	0.66	- 2.33	m, o, o, ab
2M21295678+ 1210269	M15	-	4134	0.04	- 2.27	4325	0.45	- 2.42	4310	0.76	- 1.98	4349	0.33	- 2.22	o, o
2M21295801+ 1214260	M15	-	4605	1.29	- 2.26	4855	2.0	- 2.37	4569	1.32	- 1.95	4929	2.03	- 2.19	ab
2M21295856+ 1209214	M15	-	4197	0.41	- 2.23	4300	0.3	- 2.43	4373	0.97	- 1.97	4392	0.73	- 2.14	m, o, o, ab
2M21300033+ 1210508	M15	-	4292	0.68	- 2.17	4341	0.43	- 2.4	4427	1.08	- 1.94	4434	0.83	- 2.12	d, o, o
2M21300038+ 1207363	M15	-	4394	0.72	- 2.26	4552	1.24	- 2.4	4546	1.16	- 2.0	4628	1.05	- 2.22	d, ab
2M21300224+ 1211215	M15	Rendah	4084	0.18	- 2.29	4288	0.62	- 2.39	4255	0.78	- 1.96	4371	0.59	- 2.32	d, o, o, ab
2M21300274+ 1210438	M15	Tinggi	4271	0.59	- 2.24	4275	0.5	- 2.39	4432	1.05	- 1.94	4389	0.66	- 2.16	o, o, ab
2M21300637+ 1206592	M15	Tinggi	4430	0.6	- 2.33	4625	1.3	- 2.4	4640	1.2	- 1.9	4515	0.66	- 2.11	o, o, ab
2M21300696+ 1207465	M15	-	4709	0.85	- 2.3	4940	1.5	- 2.37	4656	1.02	- 1.93	4908	0.83	- 2.14	ab
2M21301049+ 1210061	M15	-	4486	1.02	- 2.1	4470	1.07	- 2.22	4668	1.41	- 1.86	4562	1.12	- 1.93	e, o, af
2M21304412+ 1211226	M15	-	4539	1.01	- 2.08	4640	1.4	- 2.37	4741	1.54	- 1.88	4729	1.27	- 1.95	ab
2M19533747+ 1844596	M71	Tinggi	4069	1.33	- 0.7	4200	1.2	- 0.83	4068	1.34	- 0.69	4127	1.1	- 0.8	p, af
2M19533757+ 1847286	M71	Tinggi	3906	1.22	- 0.58	3996	0.88	- 0.43	3918	1.15	- 0.56	3974	0.84	- 0.68	p, w, af
2M19533986+ 1843530	M71	Tinggi	4230	1.52	- 0.68	4300	1.25	- 0.7	4204	1.42	- 0.66	4257	1.27	- 0.74	p, af
2M19534750+ 1846169	M71	Tinggi	4259	1.6	- 0.65	4367	1.55	- 0.72	4270	1.58	- 0.65	4283	1.25	- 0.76	a, p, af, aj
2M19534827+ 1848021	M71	Tinggi	3979	1.33	- 0.6	4055	0.8	- 0.89	3968	1.19	- 0.59	3988	0.79	- 0.71	p, aa, af
2M19535064+ 1849075	M71	Tinggi	4223	1.71	- 0.65	4291	1.4	- 0.83	4212	1.55	- 0.65	4226	1.37	- 0.71	a, p, af, aj, ak
2M19535325+ 1846471	M71	Tinggi	3896	1.15	- 0.63	4099	0.8	- 0.89	3922	1.11	- 0.61	3988	0.8	- 0.74	a, p, aa, af
2M19205287+ 3745331	N6791	Tinggi	4500	2.58	0.3	4512	2.32	0.47	4520	2.37	0.32	4590	2.31	0.26	b, t
2M19205629+ 3744334	N6791	Tinggi	4472	2.53	0.32	4473	2.33	0.56	4456	2.26	0.34	4581	2.27	0.3	b, t
2M19411355+ 4012205	N6819	-	4802	2.51	0.02	4835	2.61	0.1	4805	2.61	0.01	4783	2.67	0.03	c
2M19413031+ 4009005	N6819	-	4079	1.55	0.04	4046	1.77	- 0.18	4082	1.54	0.04	4139	1.57	0.04	v
2M23565751+ 5645272	N7789	-	4560	2.37	- 0.01	4345	2.2	0.15	4562	2.36	- 0.01	4626	2.45	0.05	ai
2M06293009-3116587	N2243	-	4595	2.08	- 0.47	4561	1.9	- 0.69	4603	2.14	- 0.48	4639	2.08	- 0.46	g, s

Catatan. 1. Kesalahan rata-rata dari parameter ASPCAP DR13.

2. Standar deviasi rata-rata dari rata-rata dari beberapa (N~ 3) sumber parameter optik.

3. Kesalahan statistik rata-rata untuk prediksi StarNet sehubungan dengan parameter ASPCAP DR13.

Sumber referensi: (a) Leep, Wallerstein & Oke (1987); (b) Carretta, Bragaglia & Gratton (2007); (c) Bragaglia dkk. (2001); (d) Carretta dkk. (2009); (e) Minniti, Olszewski & Rieke (1993); (f) Brown, Wallerstein & Oke (1991); (g) Gratton & Conte. (2009); (e) Minniti, Olszewski & Rieke (1993); (f) Brown, Wallerstein & Oke (1991); (g) Gratton & Contarini (1994); (h) Peterson dkk. (1980); (i) Randich . (2006);
(j) Cavallo & Nagar (2000); (k) Lehnert, Bell & Cohen (1991); (l) Sneden dkk. (1992); (m) Sobeck dkk. (2011); (n) Sneden dkk. (1991); (o) Sneden dkk. (1997); (p) Sneden . (1994); (q) Cohen (1979); (r) Cohen (1978); (s) Gratton (1982); (t) Gratton dkk. (2006). (2006); (u) Lai dkk. (2011); (v) Molenda-Z˙akowicz dkk. (2013); (w) Bessell (1983); (x) Sneden, Pilachowski & Kraft (2000); (y) Luck & Bond (1981); (z) Kraft dkk. (1999); (aa) Cohen (1980); (ab) Shetrone, Bolte & Stetson (1998); (ac) Kraft dkk. (1992); (ad) Kraft dkk. (1993); (ae) Roederer & Sneden (2011); (af) Carretta & Gratton (1997); (ag) Kraft dkk. (1997); (ah) Domba dkk. (2015). (2015); (ai) Pilachowski (1985); (aj) Gratton, Quarta & Ortolani (1986); (ak) Pilachowski, Sneden & Wallerstein (1983); (al) Pilachowski, Leep & Wallerstein (1980); (am) Pancino dkk. (2010).

Penyelidikan kami telah mengungkap banyak bintang dengan parameter optik yang tidak lengkap dalam literatur (misalnya T_{eff}, log g, atau [Fe/H] yang hilang), atau parameter IR yang tidak lengkap dalam pangkalan data ASPCAP (misalnya, mungkin disebabkan oleh masalah akuisisi data, seperti rendahnya S/N atau per-sistensi). Kami telah menghapus bintang-bintang tersebut dari patokan kami, serta target-target dalam basis data APOGEE dengan sebaran RV yang tinggi di antara kunjungan-kunjungan individual (yang biasanya mengindikasikan potensi sistem bintang ganda). Gbr. 13 membandingkan parameter bintang untuk sampel akhir bintang-bintang patokan optik kami (seperti yang tercantum di bawah ini, dengan pencilan yang jelas telah dihilangkan). Ditemukan adanya offset sistematis yang kecil pada T_{eff}, log g, dan [Fe/H], meskipun umumnya berada dalam kesalahan 1σ yang dikutip.

Makalah ini telah diketik dari file TEX/LATEX yang disiapkan oleh penulis.

Diunduh dari https://academic.oup.com/mnras/article/475/3/2978/4775133 oleh tamu pada tanggal 08 Juli 2024